Классификация дохода с помощью дерева решений

Основы интеллектуального анализа данных

Формулировка задания

Разработать программу классификации с помощью дерева решений. Предусмотреть выбор набора данных и критерия разбиения: Information gain, Gain ratio или Gini index. На данных Census Income построить и визуализировать деревья, используя всю исходную обучающую выборку.

Добавить параметр доли обучения и вычисление accuracy, precision, recall и F1. При фиксированном критерии провести эксперименты с соотношениями обучающей и тестовой выборок 60:40, 70:30, 80:20 и 90:10. Построить график зависимости метрик от доли обучения и объяснить результаты.

Репозиторий

Ссылка на каталог репозитория: https://github.com/DexScen/IntDataUNI/tree/main/intdata2

Данные и реализация алгоритма

Использован набор Adult (Census Income): 32 561 запись в исходной обучающей выборке и 16 281 запись в тестовой, всего 48 842. Каждая строка описывает человека с помощью 14 признаков: возраста, образования, занятости, семейного положения и других характеристик. Целевая переменная - годовой доход не более 50 000 долларов или более 50 000 долларов.

Доход выше 50 000 долларов имеют 11 687 человек (23,93%). Этот класс кодируется числом 1, остальные записи - числом 0. Из меток тестовой выборки удаляется завершающая точка. Неизвестные категории «?» заменяются на «Unknown»; строки не удаляются. Шесть признаков числовые, восемь - категориальные.

Дерево реализовано самостоятельно по рекурсивной схеме TreeGrowth из презентации. В каждом узле перебираются допустимые разбиения, выбирается лучшее и создаются дочерние узлы. Для числа используется условие «признак ≤ порог», для категории - «признак = значение». Порог берется между соседними различными числами; категориальные значения проверяются по одному против остальных.

Information gain выбирает максимальное уменьшение энтропии. Gain ratio делит это уменьшение на энтропию размеров двух ветвей. Здесь используется непосредственно это отношение, без дополнительных эвристик C4.5. Для Gini index выбирается максимальное уменьшение индекса Джини, то есть минимальная взвешенная неоднородность дочерних узлов.

Во всех опытах максимальная глубина равна 3, минимальный размер листа - 30 записей. Ограничения одинаковы и заданы заранее, чтобы полностью показать деревья. Рост также прекращается в чистом узле или при отсутствии полезного разбиения. Лист предсказывает наиболее частый класс; при равенстве частот - класс 0.

Функция classify получает данные, критерий, долю обучения и ограничения роста; возвращает дерево, размеры выборок и метрики. При доле 1,0 для оценки передается отдельная тестовая таблица. Код содержит краткие комментарии к назначению функций, входным параметрам и результатам.

Сравнение критериев разбиения

Все три модели обучены на 32 561 записи исходной обучающей выборки. Оценка выполнена на 16 281 отдельной тестовой записи. Положительный класс для precision, recall и F1 - доход >50K; метрики в таблице приведены в процентах.

Таблица 1. Качество моделей на исходной тестовой выборке, %

Критерий	Accuracy	Precision	Recall	F1
Information gain	84,48	75,53	50,73	60,69
Gain ratio	80,80	98,13	19,08	31,95
Gini index	84,48	75,53	50,73	60,69

На рисунках n - число обучающих записей в узле. Ветка «да» идет влево, «нет» - вправо. Синий лист предсказывает ≤50K, оранжевый - >50K. Показаны все узлы построенных деревьев.

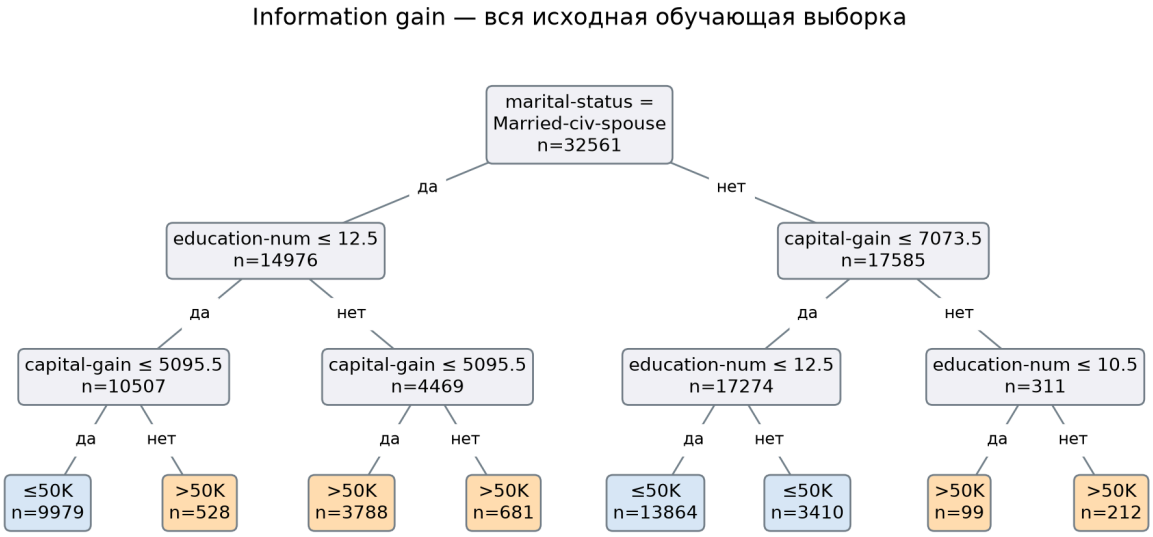


Рисунок 1. Дерево с критерием Information gain

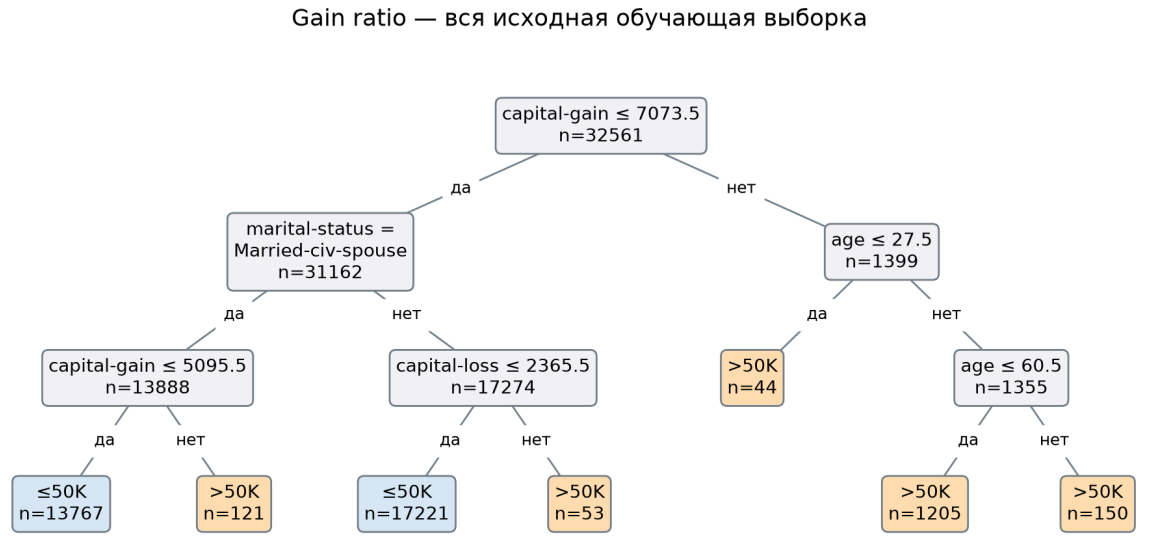


Рисунок 2. Дерево с критерием Gain ratio

Интерпретация построенных деревьев

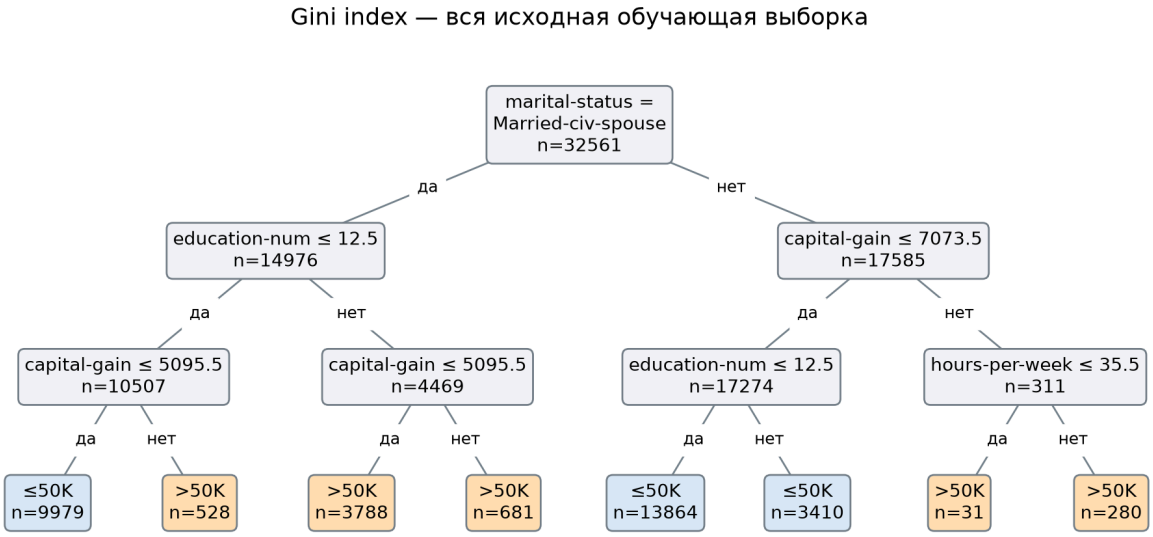


Рисунок 3. Дерево с критерием Gini index

Information gain и Gini index дали одинаковые значения метрик: accuracy - 84,48%, F1 - 60,69%. Их корневое условие проверяет семейное положение Married-civ-spouse. Среди последующих условий встречаются уровень образования education-num и прирост капитала capital-gain. Совпадение метрик не означает, что два критерия всегда создают одинаковые деревья.

Например, на рисунке 1 для записи с marital-status = Married-civ-spouse, education-num ≤ 12,5 и capital-gain > 5095,5 модель предсказывает доход >50K. В соответствующем листе находится 528 обучающих записей. Это число всех записей листа, а не число правильных ответов; предсказание соответствует большинству в нем.

Gain ratio начинает с capital-gain ≤ 7073,5. При заданной небольшой глубине он реже выдает класс >50K: из 748 таких ответов 734 верны. Поэтому precision достигает 98,13%, но из 3 846 людей с высоким доходом найдены лишь 734 - recall равна 19,08%. Пропущены 3 112 человек; F1 составляет 31,95%. Высокая precision сама по себе не означает высокое общее качество.

Оценка качества и порядок экспериментов

Accuracy - доля правильных ответов среди всех тестовых записей. Precision = TP / (TP + FP), recall = TP / (TP + FN), F1 = 2TP / (2TP + FP + FN). Здесь TP - верно найденный высокий доход, FP - ошибочный ответ >50K, FN - пропущенный высокий доход. Метрики характеризуют разные виды ошибок.

Во втором эксперименте обе исходные выборки объединены в 48 842 записи. Для каждой доли обучение и тест выделяются заново с сохранением пропорций классов (stratify) и random_state = 42. Внутри запуска строки этих двух частей не пересекаются. Фиксируются Information gain, глубина 3 и минимум 30 записей в листе.

Это отдельный протокол оценки: тестовые части отличаются от исходной тестовой выборки и меняются между долями. Каждая модель оценивается только на отложенных для нее записях. Настройка параметров по тестовым ответам не выполняется.

Деревья при долях обучения 60 и 70 процентов

При соотношении 60:40 обучение использует 29 305 записей, тест - 19 537. При 70:30 размеры равны 34 189 и 14 653. Ниже показаны деревья целиком с теми же обозначениями узлов и ветвей.

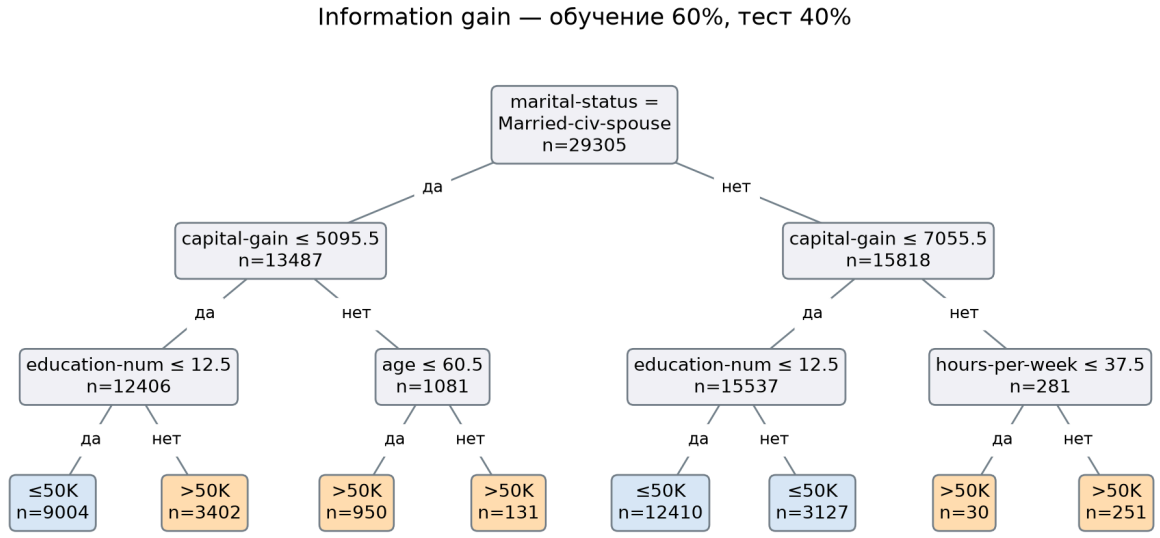


Рисунок 4. Information gain при соотношении обучение : тест = 60:40

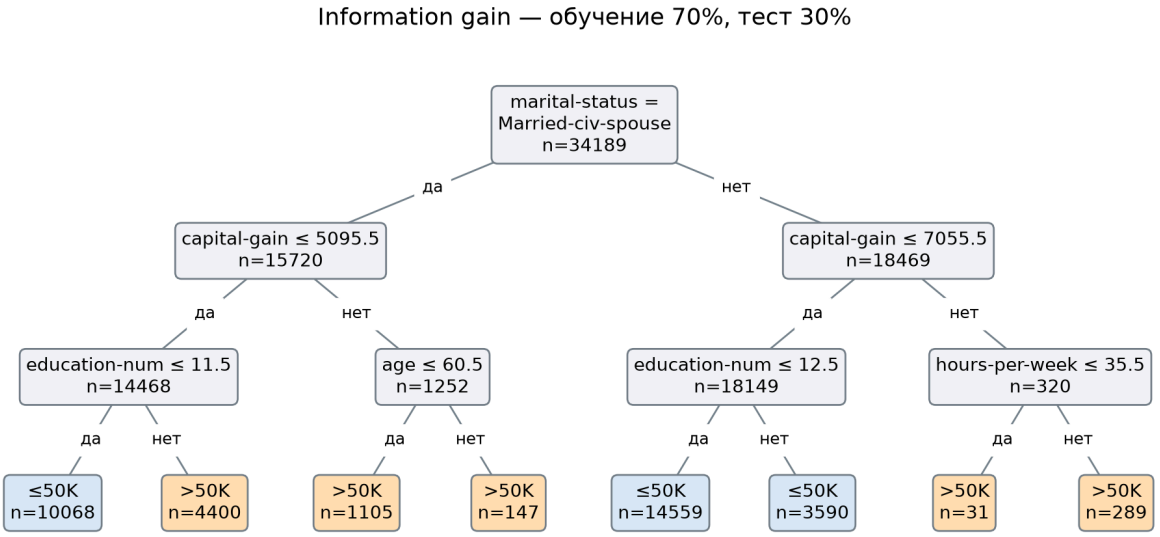


Рисунок 5. Information gain при соотношении обучение : тест = 70:30

Корневое условие в обоих запусках одинаково. При доле 70% порог education-num в левой части дерева меняется с 12,5 на 11,5. Эта ветвь относит более широкую группу уровней образования к высокому доходу. В данном запуске recall увеличивается, а precision уменьшается.

Деревья при долях обучения 80 и 90 процентов

При соотношении 80:20 обучение содержит 39 073 записи, тест - 9 769. При 90:10 - 43 957 и 4 885 соответственно. Округление размеров до целых строк выполняется функцией разбиения.

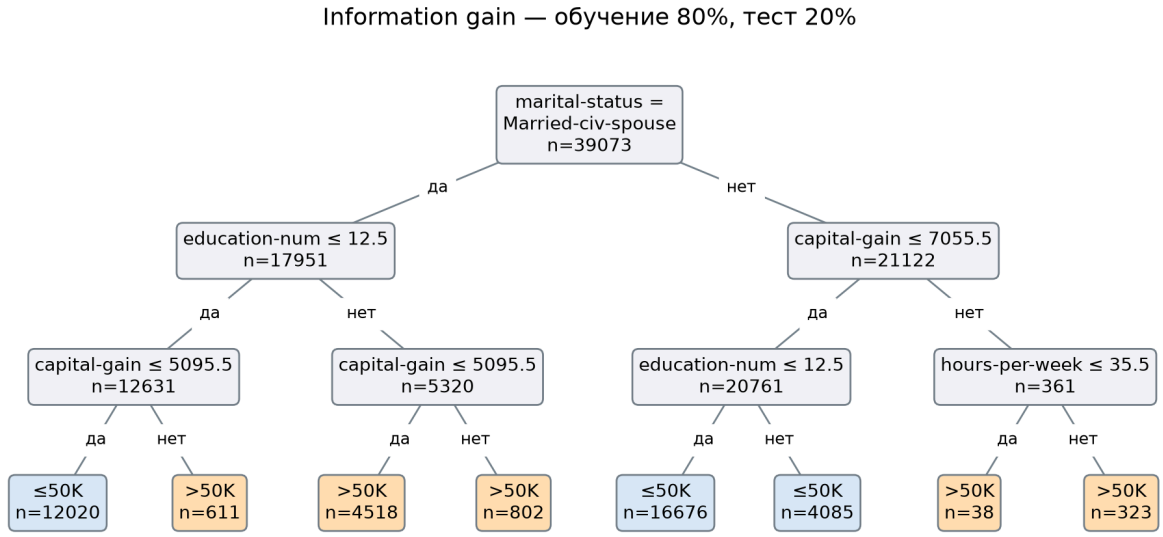


Рисунок 6. Information gain при соотношении обучение : тест = 80:20

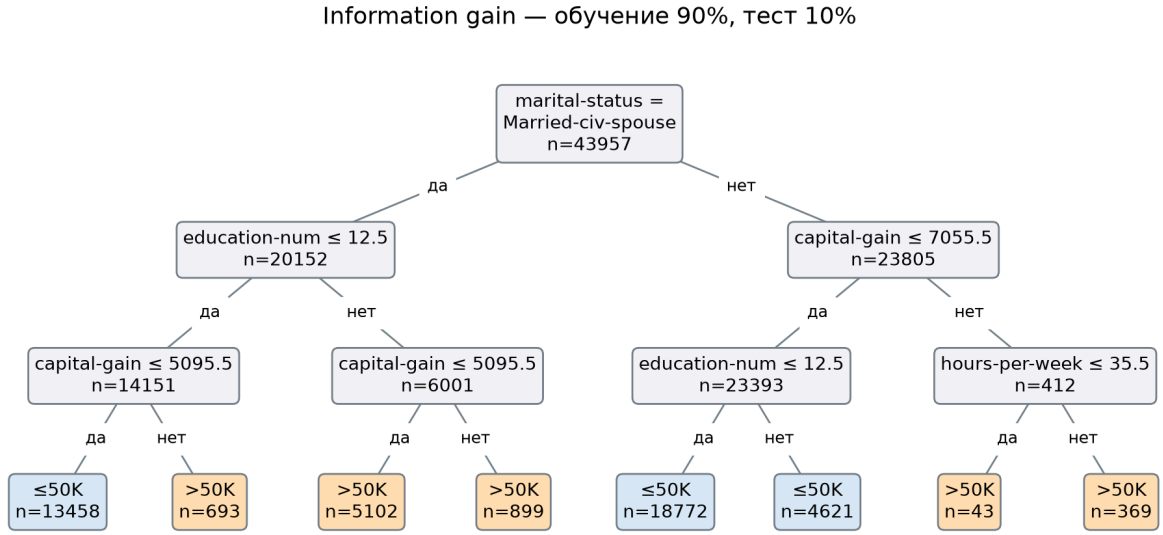


Рисунок 7. Information gain при соотношении обучение : тест = 90:10

Для долей 80% и 90% совпадают структура, признаки и пороги разбиений, но меняется число записей в узлах. На втором уровне левой ветви сначала проверяется education-num. Во всех четырех опытах корень использует marital-status. Это показывает устойчивость выбора корневого условия в данных запусках, но не устанавливает причинную связь признаков с доходом.

Зависимость качества от доли обучения

Таблица 2. Размеры выборок и показатели качества, %

Обучение : тест	Обучение, строк	Тест, строк	Accuracy	Precision	Recall	F1
60:40	29 305	19 537	84,62	76,72	51,32	61,50
70:30	34 189	14 653	84,38	73,74	53,91	62,28
80:20	39 073	9 769	84,55	75,92	51,92	61,67
90:10	43 957	4 885	84,48	76,18	51,15	61,21

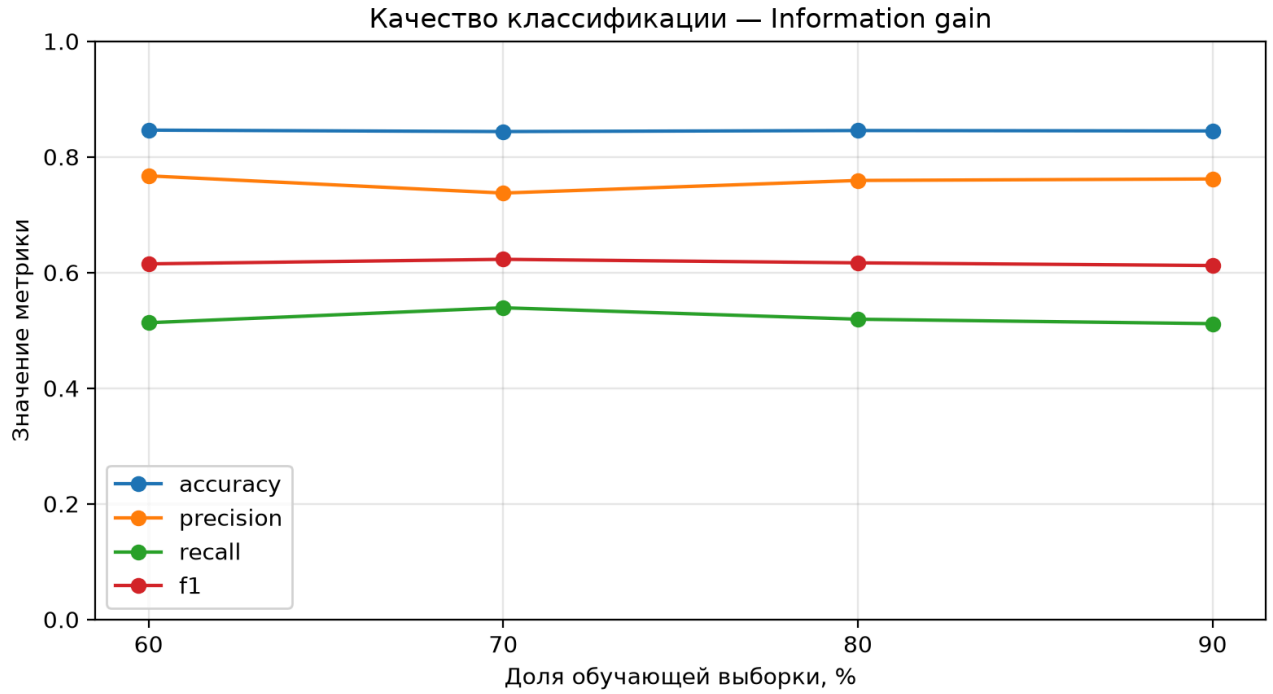


Рисунок 8. Показатели качества при изменении доли обучения

Accuracy находится в узком диапазоне 84,38–84,62%. В этой серии увеличение доли обучения с 60% до 90% не дает последовательного роста качества. Изменяются состав теста и отдельные условия дерева; дополнительно сложность модели ограничена глубиной.

Precision составляет 73,74–76,72%, recall - 51,15–53,91%. Следовательно, примерно три четверти ответов «высокий доход» верны, но модель находит лишь около половины людей этого класса. Большинство записей относится к ≤50K, поэтому одна accuracy скрывала бы значительную долю пропусков высокого дохода.

Наибольшая F1 получена при соотношении 70:30 - 62,28%. Однако для каждой доли проверено лишь одно разбиение с отличающейся тестовой частью. Поэтому считать это соотношение оптимальным нельзя.

Выводы

Реализовано дерево с тремя критериями, настройкой доли обучения и четырьмя метриками. Построены все требуемые визуализации. При глубине 3 Information gain и Gini дали более высокую F1, чем прямой Gain ratio. Увеличение доли обучения не обеспечило последовательного улучшения качества.