Ансамблевая классификация дохода

Основы интеллектуального анализа данных

Формулировка задания

Разработать программу классификации с использованием ансамбля. Параметры программы: набор данных, техника ансамблевой классификации, количество участников и настройки выбранной техники. На данных Adult из задания о деревьях решений провести эксперименты, изменяя число участников от 50 до 100 с шагом 10.

Вычислить accuracy, precision, recall и F1, построить зависимости метрик от количества участников. Нанести на графики соответствующие результаты одиночного дерева из предыдущего задания и объяснить полученные различия.

Репозиторий

Ссылка на каталог репозитория: https://github.com/DexScen/IntDataUNI/tree/main/intdata3

Данные и условия сравнения

Использован набор Census Income (Adult). Обучение проводится на всех 32 561 записях исходной обучающей выборки, проверка - на 16 281 записи исходной тестовой выборки. Разделение одинаково во всех опытах и совпадает с первым экспериментом предыдущего задания. Четырнадцать признаков описывают возраст, образование, занятость и другие характеристики человека.

Класс 1 означает годовой доход более 50 000 долларов, класс 0 - не более 50 000. В тесте положительный класс содержит 3 846 записей. Неизвестные категории «?» заменяются на «Unknown» без удаления строк; из меток теста удаляется завершающая точка. Категории кодируются отдельными столбцами 0/1, числовые признаки сохраняются. Кодировщик обучается только на обучающих данных; после преобразования получено 108 признаков.

Реализация и параметры ансамблей

Бэггинг строит деревья на случайных выборках с возвращением: одна запись может встречаться несколько раз. Ответ определяется большинством голосов, как в алгоритме на слайдах 40–41. Случайный лес дополнительно выбирает случайное подмножество признаков при поиске каждого разбиения. Для обоих методов голосование по меткам классов реализовано явно; при равенстве голосов выбирается класс 0.

AdaBoost обучает участников последовательно и увеличивает относительный вес ошибочно распознанных записей. Итог определяется взвешенным голосованием. В используемой библиотечной реализации веса передаются непосредственно при обучении дерева; в примере презентации по ним формируется новая случайная выборка.

Все базовые деревья имеют глубину не более 3, минимум 30 записей в листе и критерий entropy (Information gain). Для бэггинга и леса max_samples = 1,0: размер выборки с возвращением равен размеру обучения. Для леса max_features = sqrt применяется к 108 закодированным признакам; для AdaBoost learning_rate = 0,5. Случайность фиксируется random_state = 42. Внутри каждого метода меняется только число участников. Использована scikit-learn 1.9.1.

Результаты экспериментов

В качестве базы взято собственное дерево Information gain из задания 3 с глубиной 3 и минимумом 30 записей в листе. На той же тестовой выборке оно дало TP = 1951, TN = 11803, FP = 632, FN = 1895. Повторный запуск прежнего алгоритма подтвердил эти значения.

Accuracy показывает долю всех правильных ответов. Precision - долю верных среди ответов >50K, recall - долю найденных записей >50K. F1 - гармоническое среднее precision и recall. В таблице метрики представлены в процентах; N - число участников. Во всех 18 опытах фактическое число обученных деревьев совпало с заданным.

Таблица 1. Качество ансамблей и одиночного дерева, %

Метод	N	Accuracy	Precision	Recall	F1
Дерево из задания 3	1	84,48	75,53	50,73	60,69
Бэггинг	50	84,48	75,53	50,73	60,69
Бэггинг	60	84,48	75,53	50,73	60,69
Бэггинг	70	84,48	75,53	50,73	60,69
Бэггинг	80	84,48	75,53	50,73	60,69
Бэггинг	90	84,48	75,53	50,73	60,69
Бэггинг	100	84,48	75,53	50,73	60,69
Лес	50	77,54	100,00	4,94	9,42
Лес	60	77,85	100,00	6,24	11,75
Лес	70	77,18	100,00	3,41	6,59
Лес	80	77,30	100,00	3,90	7,51
Лес	90	77,20	100,00	3,48	6,73
Лес	100	77,18	100,00	3,38	6,54
AdaBoost	50	85,76	77,52	55,95	65,00
AdaBoost	60	85,77	77,43	56,11	65,07
AdaBoost	70	85,82	77,34	56,53	65,31
AdaBoost	80	85,95	77,40	57,25	65,82
AdaBoost	90	85,96	77,62	56,99	65,73
AdaBoost	100	85,95	77,57	57,02	65,73

При заданных настройках AdaBoost имеет более высокие значения всех четырех метрик, чем одиночное дерево. Бэггинг повторяет его показатели при любом исследованном размере ансамбля. Случайный лес имеет precision 100%, но низкую полноту: правильно распознанные случаи высокого дохода составляют лишь малую часть этого класса.

Визуализация и смысл результатов

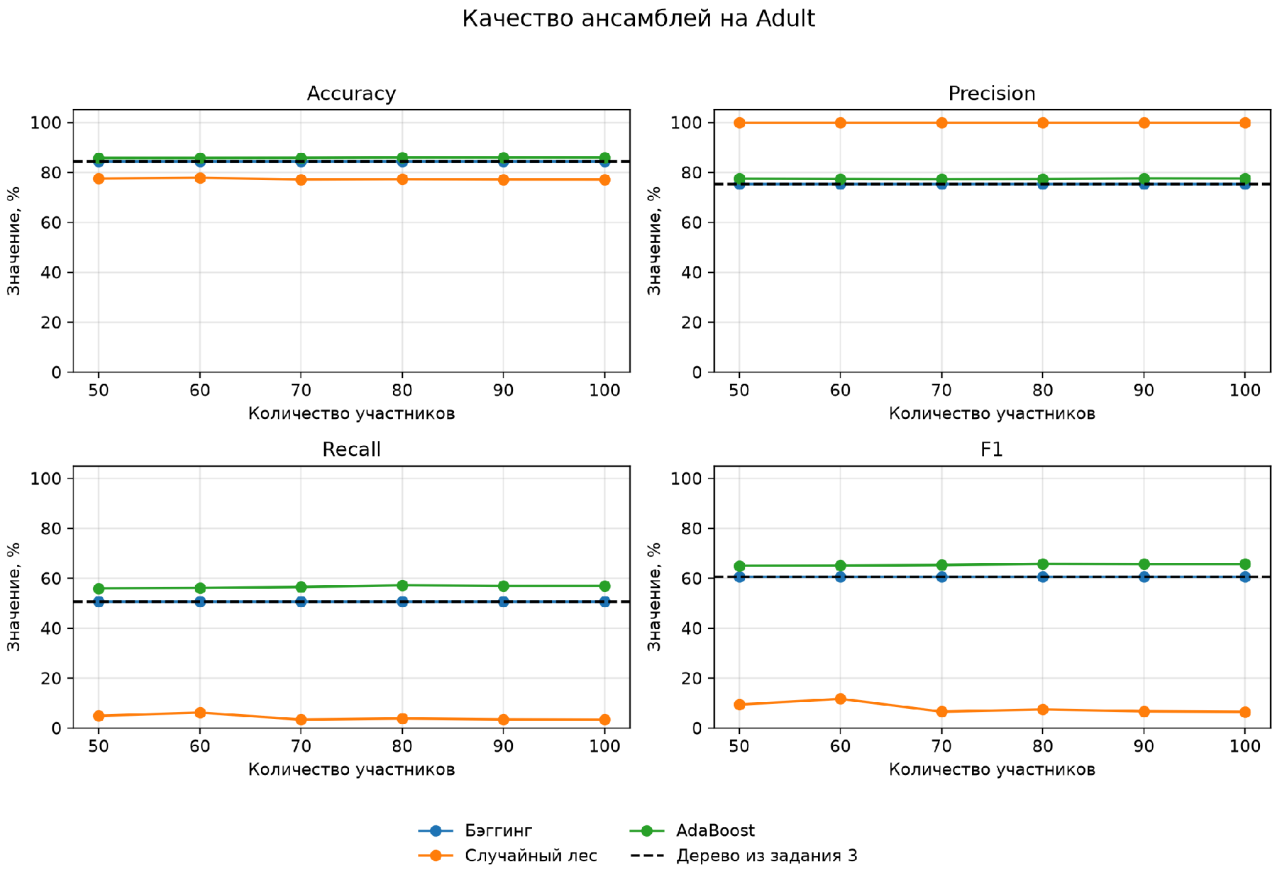


Рисунок 1. Зависимость четырех метрик от количества участников ансамбля

Пунктир обозначает результат одиночного дерева. Линия бэггинга совпадает с ним на всех панелях: рост с 50 до 100 деревьев не изменил метрики. При небольшой глубине добавление похожих участников может сохранять общие ошибки.

У случайного леса recall находится в пределах 3,38–6,24%, несмотря на precision 100%. Например, ансамбль из 100 деревьев нашел только 130 из 3 846 записей с высоким доходом и пропустил 3 716. Все 130 положительных ответов верны, но это не делает модель полезной для поиска большинства таких записей. Полученный результат согласуется с недостаточной сложностью деревьев при глубине 3, случайном выборе признаков и голосовании большинства.

AdaBoost повышает F1 до 65,00–65,82%. При 80 участниках F1 равна 65,82%, что выше базы на 5,13 процентного пункта; recall повышается с 50,73% до 57,25%. Последовательное усиление внимания к ошибкам помогает найти больше записей высокого дохода. Рост размера до 100 не улучшает все метрики: F1 при этом составляет 65,73%.

Выводы

В этой серии AdaBoost улучшил результаты одиночного дерева, бэггинг сохранил их, а случайный лес с выбранными ограничениями часто пропускал высокий доход. Результаты относятся к указанным настройкам и одному random_state. Они не доказывают универсальное превосходство метода или оптимальность 80 участников.