Практическая работа по интеллектуальному анализу данных

Репозиторий гит - https://github.com/DexScen/IntDataUNI/tree/main/intdata4

Разделительная кластеризация клиентов банка

В работе реализованы k-Means и k-Medoids, исследованы данные 850 клиентов банка и влияние случайного повреждения объектов. На исходных данных оба алгоритма достигают наибольшего среднего силуэта при четырех кластерах в диапазоне k от 3 до 9. Добавление шума увеличивает ошибку, но изменение разбиения зависит от алгоритма и конкретного повторения.

1 Формулировка задания

Требуется разработать программу, принимающую набор данных и число кластеров, и выполнить разделительную кластеризацию алгоритмами k-Means и k-Medoids. Результат должен содержать координаты объектов, назначенные кластеры и ошибку кластеризации.

Необходимо провести эксперименты на наборе customers, построить точечные графики с окраской по кластерам и графики зависимости ошибки от k. Затем следует добавить параметр доли зашумленных объектов и повторить эксперименты для долей 1%, 3%, 5%, 10% и значений k от 3 до 9. Результаты требуется объяснить в структурированном отчете.

2 Исходные тексты и материалы

Каталог включает автономный ноутбук Customers_Partition_Clustering_Colab.ipynb, модули src/clustering.py и src/experiments.py, исходные customers.csv и custmers.txt, таблицы результатов и все изображения. Ноутбук содержит копию CSV и выполняется в Google Colab через команду «Выполнить все».

Компонент	**Назначение**
clustering.py	Алгоритмы, стандартизация, шум, экспорт координат и интерфейс командной строки
experiments.py	Полная сетка параметров, метрики и визуализация
results/metrics.csv	210 отдельных запусков с параметрами и ошибками
results/all_points.csv.gz	178 500 назначений объектов и использованные координаты

В основе реализации лежит лекция «04 Кластеризация», прежде всего слайды 9–14, 27–30, 64 и 67–68. Квадратичная ошибка PAM выбрана в соответствии со слайдом 29.

3 Данные и подготовка признаков

Архив customers.zip содержит таблицу customers.csv и описание custmers.txt. В таблице 850 строк и 10 столбцов. Пропуски встречаются только в Defaulted (150 строк, 17,65%). В шести используемых признаках пропусков нет, поэтому для кластеризации сохранены все 850 клиентов.

Поле	**Смысл**	**Использование**
Row и CustomerId	Номер строки и идентификатор клиента	Исключены из расстояний
Age	Возраст, полных лет	Включен
Education	Целочисленный код образования	Исключен как код категории
YearsEmployed	Трудовой стаж, полных лет	Включен
Income	Годовой доход, тыс. долларов	Включен
CardDebt	Задолженность по карте	Включен
OtherDebt	Прочие задолженности	Включен
Defaulted	Банкротство, 0/1; 150 пропусков	Исключен из кластеризации
DebtIncomeRatio	Отношение долга к доходу	Включен

Идентификаторы отражают порядок записей и не характеризуют сходство клиентов. Расстояние между кодами Education не имеет установленного количественного смысла. Defaulted не используется ни как признак, ни как целевая метка: задача состоит в поиске неизвестных групп, а не в обучении классификатора банкротства.

Признаки стандартизованы: из каждого значения вычтено среднее, затем результат разделен на стандартное отклонение данного признака. Используется стандартное отклонение совокупности, ddof=0. Это выравнивает масштаб возраста, стажа, дохода и долгов.

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}$$

Средние и масштабы рассчитываются один раз до добавления шума. В зашумленных условиях применяется та же шкала. Повторная стандартизация скрывала бы часть искусственно внесенного разброса и затрудняла сравнение ошибок.

Обобщенная функция подготовки умеет заполнять пропуски числовых признаков медианами и отклоняет полностью пустые столбцы и бесконечные значения. Для customers заполнение не понадобилось. Финансовые признаки коррелируют: DebtIncomeRatio связан с доходом и долгами. Поэтому долговая нагрузка получает дополнительный вес; выводы относятся именно к выбранным шести признакам.

4 Реализация алгоритмов

4 1 Общая ошибка кластеризации

Оба алгоритма назначают объект ближайшему представителю по евклидову расстоянию в шестимерном стандартизованном пространстве. Основная ошибка SSE представляет сумму квадратов этих расстояний. Номер кластера является условным обозначением.

$$SSE = \sum_{i=1}^{n} \|z_i - c_{a(i)}\|^2$$

Здесь z_i - координаты объекта, a(i) - метка его кластера, c - представитель. Для k-Means представитель является средним, для k-Medoids - строкой набора. Чем меньше SSE при одинаковом наборе и k, тем компактнее объекты относительно представителей.

4 2 Метод k Means

Начальные центроиды выбираются из данных по схеме D^2: вероятность очередной точки пропорциональна квадрату расстояния до ближайшего уже выбранного центра. Затем поочередно выполняются назначение ближайшему центру и пересчет среднего каждого кластера. Остановка происходит при неизменности меток либо после 300 итераций.

Если кластер опустел, в него переносится наиболее удаленный объект из кластера с числом объектов больше одного. Каждый запуск использует пять начальных конфигураций; сохраняется решение с минимальной SSE. Это уменьшает зависимость от инициализации, но не доказывает глобальную оптимальность.

4 3 Метод k Medoids

Реализован полный этап SWAP алгоритма PAM. Выбираются k медоидов, объекты назначаются ближайшим медоидам, после чего оцениваются все обмены одного медоида и одного не-медоида. Выполняется обмен с наибольшим уменьшением цели. Алгоритм останавливается, когда улучшающих одиночных обменов нет.

В отличие от случайной проверки обмена на слайде 29, полный перебор кандидатов дает проверяемый критерий остановки. Ближайший и второй ближайший медоиды позволяют векторизовать расчет стоимости обменов. Медоиды всегда остаются реальными объектами. Пять стартов и предел 300 итераций заданы так же, как у k-Means.

Основной PAM минимизирует квадраты расстояний, как записано в лекции. Дополнительный параметр power=1 включает сумму обычных расстояний. При этой цели вклад далекого объекта растет линейно, а при SSE - квадратично. Поэтому тезис о меньшей чувствительности медоидов к выбросам требует уточнения целевой функции.

k-Means требует примерно $O(R \cdot T \cdot n \cdot k \cdot d)$ операций. PAM дополнительно хранит матрицу расстояний $O(n^2)$; используемый векторизованный SWAP требует порядка $O(n^2+n \cdot k)$ операций на шаг после подготовки расстояний. Здесь R - число стартов, T - число шагов.

5 План экспериментов и модель шума

Исследована полная сетка: два алгоритма, семь значений k от 3 до 9, пять уровней шума (включая 0%) и три повторения с зернами 2026, 2027, 2028. Всего выполнено 210 запусков, то есть 1050 стартовых конфигураций. Во всех запусках выполнен критерий сходимости; предельное число итераций не стало причиной остановки.

Для доли p выбирается m = floor(p·n + 0,5) различных строк. У каждой выбранной строки одна случайная координата изменяется на случайную величину от 3 до 6 исходных стандартных отклонений со случайным знаком. Это модель повреждения измерений. Значения не обрезаются до допустимых банковских диапазонов.

Заданная доля	Изменено строк	Фактическая доля
0%	0	0%
1%	9	1,06%
3%	26	3,06%
5%	43	5,06%
10%	85	10,00%

Для одного зерна используется одна перестановка объектов и заранее выбранные координаты и сдвиги. При увеличении p набор испорченных строк расширяется, а уже заданные сдвиги сохраняются. Для обоих алгоритмов и всех k внутри одного условия данные одинаковы. Три зерна меняют шум и начальные конфигурации.

5 1 Показатели качества

SSE оценивает компактность зашумленного набора относительно его представителей. Для удобства также выводится SSE/n. Силуэт оценивает сходство точки с собственным кластером по сравнению с ближайшим другим кластером. Он рассчитывается по обычным евклидовым расстояниям в полном пространстве шести признаков.

$$s(i) = \frac{b(i) - a(i)}{max[a(i), b(i)]}$$

a(i) - среднее расстояние до других точек своего кластера; b(i) - наименьшее среднее расстояние до другого кластера. Для кластера из одной точки силуэт полагается равным нулю. Средний силуэт лежит от −1 до 1; большее значение лучше.

Для отделения прямой цены шумных координат от сдвига представителей дополнительно измеряется средний квадрат расстояния исходных, неповрежденных координат всех 850 точек до ближайшего представителя шумного решения. ARI сравнивает метки с безшумным запуском того же алгоритма, k и зерна только на неизмененных строках. ARI=1 означает совпадение разбиений; около 0 - случайный уровень согласования.

На графиках ошибки показано среднее по трем повторениям и одно стандартное отклонение. Это разброс наблюдений, а не доверительный интервал. На точечных графиках показан первый повтор, seed=2026.

6 Ошибка и число кластеров на исходных данных

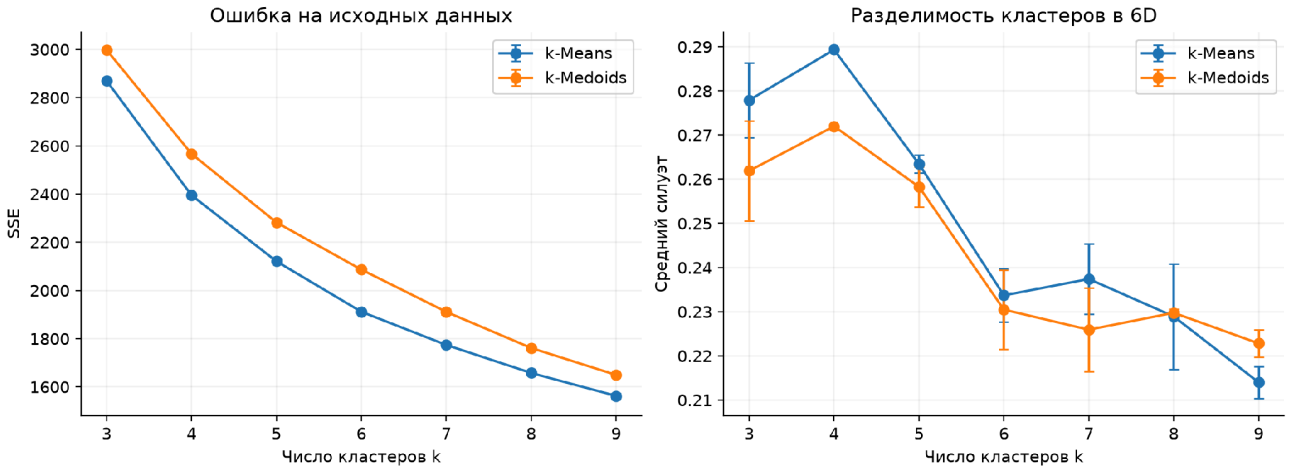


Рисунок 1. SSE и средний силуэт без искусственного шума. Среднее и разброс трех повторов.

k	SSE k-Means	SSE k-Medoids	Силуэт k-Means	Силуэт k-Medoids
3	2870,15	2998,28	0,2779	0,2619
4	2395,03	2567,11	0,2893	0,2720
5	2120,98	2282,34	0,2634	0,2583
6	1911,71	2086,72	0,2337	0,2305
7	1773,99	1911,23	0,2374	0,2259
8	1657,57	1761,39	0,2289	0,2298
9	1562,45	1649,33	0,2140	0,2228

При увеличении k оба алгоритма уменьшают SSE. Самый большой шаг уменьшения в исследованном диапазоне приходится на переход от трех к четырем кластерам; далее выигрыш постепенно сокращается. Резкого однозначного локтя нет, поэтому для выбора k дополнительно используется силуэт.

Максимальный средний силуэт у обоих методов достигается при k=4: 0,2893 для k-Means и 0,2720 для k-Medoids. Поэтому четыре кластера выбраны для подробной визуализации и анализа шума. Выбор относится к диапазону 3..9, выбранной стандартизации и шести признакам, а не устанавливает единственное истинное число сегментов.

k-Means имеет меньшую SSE во всех показанных чистых условиях. Его представители могут находиться в любой точке пространства, тогда как медоиды ограничены существующими клиентами. Это объясняет результат; для отдельных локальных решений разных методов универсальное сравнение не гарантируется.

7 Визуализация и профили четырех кластеров

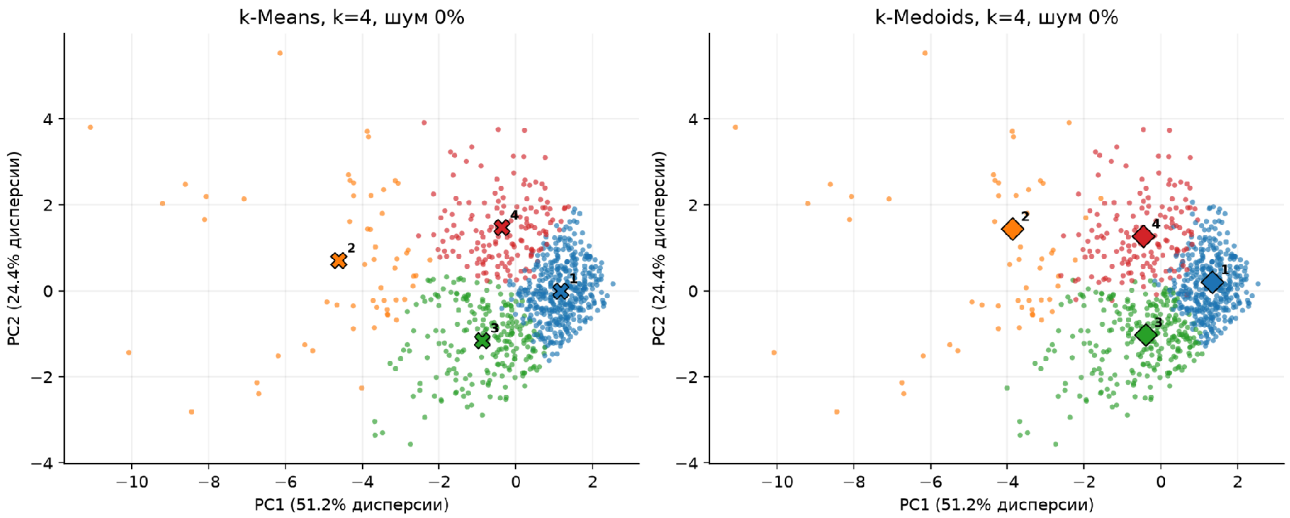


Рисунок 2. Исходные 850 клиентов в осях PCA. Кресты - центроиды; ромбы - медоиды.

Цвет точки задается кластеризацией в 6D. Для изображения используется PCA, обученная один раз на исходных стандартизованных данных. PC1 объясняет 51,21% дисперсии, PC2 - 24,36%; вместе 75,56%. Проекция теряет 24,44% информации, поэтому перекрытие цветов на плоскости не означает совпадение групп в 6D. Цвета двух методов согласованы по наибольшему пересечению кластеров.

Кластер	n	Возраст	Стаж	Доход	Долг по карте	Прочий долг	Долг к доходу
1	426	30,6	4,9	29,0	0,64	1,39	7,3
2	55	43,5	18,2	126,9	7,08	11,88	17,8
3	220	42,5	15,1	67,9	1,50	3,12	7,4
4	149	33,7	6,0	36,2	2,32	4,59	19,6

Таблица 1. Средние значения исходных признаков кластеров k-Means, k=4, seed=2026. Доход приведен в тыс. долларов в год; долговые показатели - в единицах исходного набора.

Кластер 1 объединяет 426 клиентов: это самая многочисленная группа, в среднем более молодая, с меньшим доходом и небольшими долгами. Кластер 2 содержит 55 клиентов с высоким средним доходом и крупными долгами. Кластер 3 включает 220 более старших клиентов с большим стажем и умеренным отношением долга к доходу. У 149 клиентов кластера 4 отношение долга к доходу наиболее высоко при сравнительно небольшом доходе.

k-Medoids дает близкие содержательные типы, но другие границы: размеры его групп в собственном порядке меток равны 377, 265, 151 и 57. Номера в CSV условны, а цвета на рисунке сопоставлены между методами. Средние профили не являются прогнозом банкротства: Defaulted в построении разбиения не использован.

8 Влияние шума на ошибку кластеризации

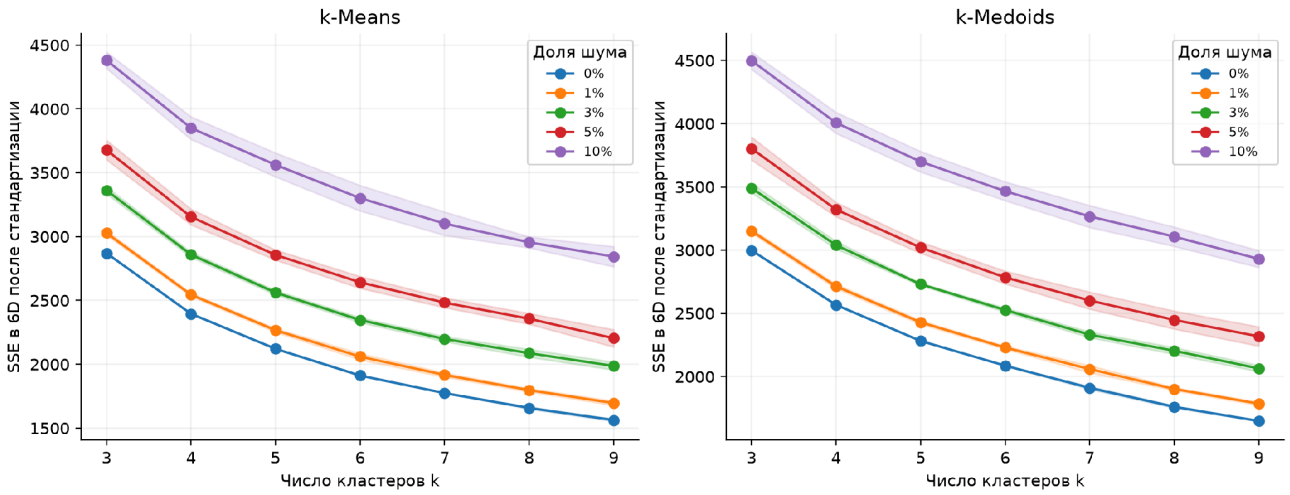


Рисунок 3. Зависимость SSE от k при пяти уровнях шума. Полосы показывают одно стандартное отклонение.

Шум	SSE k-Means	SSE k-Medoids	ARI k-Means	ARI k-Medoids
0%	2395,03 ± 0,01	2567,11 ± 0,00	1,000	1,000
1%	2544,60 ± 13,43	2713,80 ± 18,43	0,982	0,842
3%	2858,55 ± 19,91	3039,54 ± 29,79	0,905	0,801
5%	3154,17 ± 61,36	3321,30 ± 56,02	0,969	0,928
10%	3849,90 ± 88,36	4006,75 ± 82,54	0,966	0,913

Таблица 2. Основные результаты при k=4; SSE - среднее ± стандартное отклонение, ARI рассчитан только на строках, которые не изменялись в данном условии.

При 10% шума средняя SSE k-Means увеличивается на 60,7%, а k-Medoids - на 56,1% относительно собственного безшумного результата. Значительная часть прироста возникает непосредственно из-за больших сдвигов поврежденных координат. Сам рост SSE еще не доказывает столь же сильный сдвиг групп остальных клиентов.

В этой сетке увеличение k уменьшает SSE при всех долях шума. Новые представители могут частично обслуживать поврежденные или удаленные точки; это не означает появление новых содержательных клиентских сегментов. У независимых локальных запусков строгая монотонность теоретически не гарантируется.

9 Точечные графики k Means при шуме

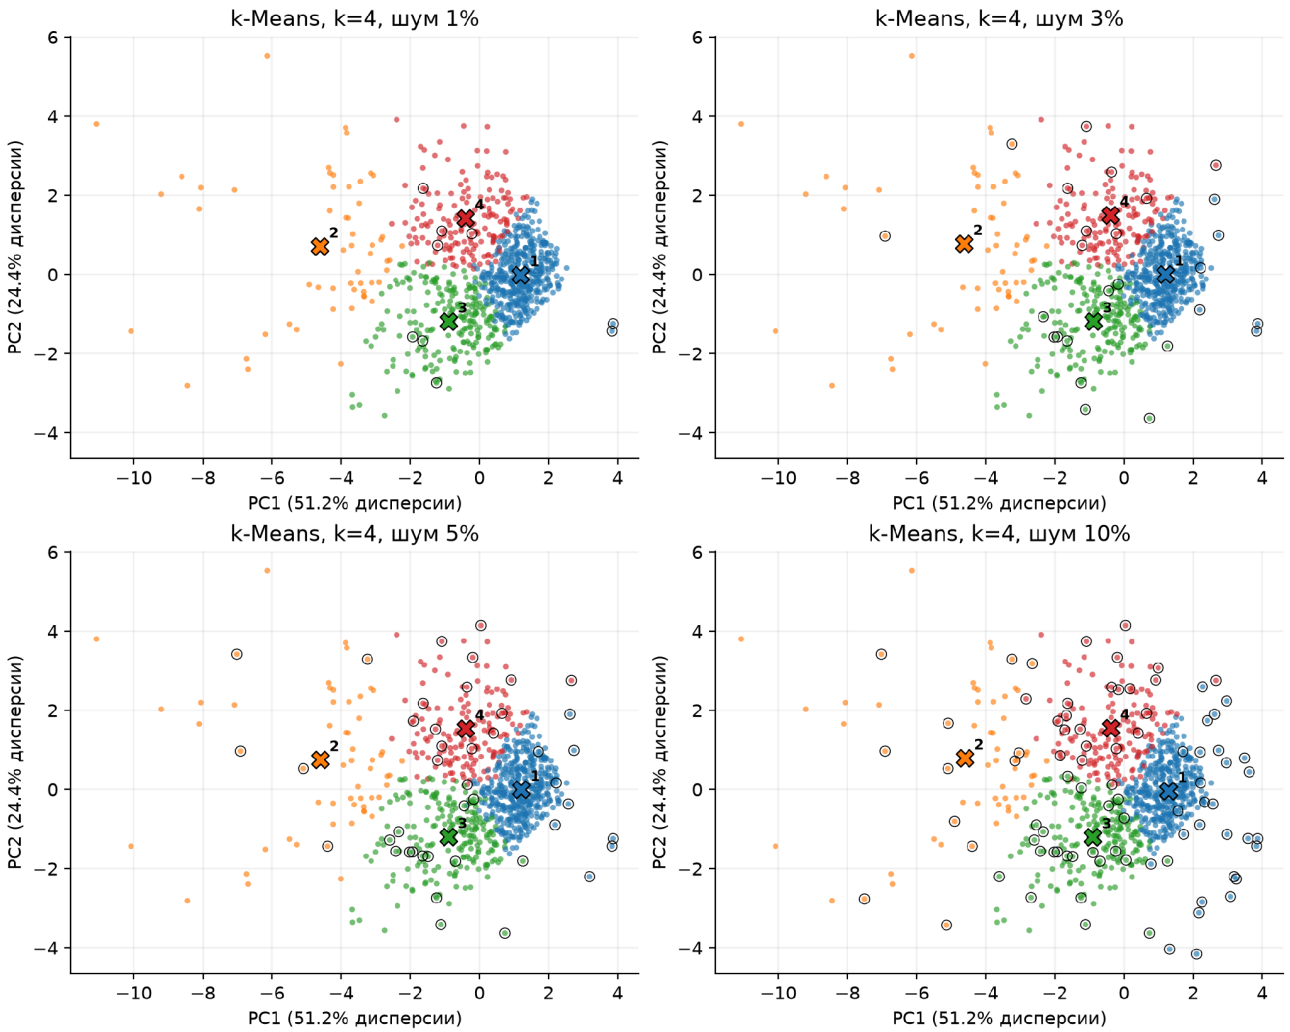


Рисунок 4. k-Means, k=4, seed=2026. Доли шума 1%, 3%, 5%, 10%. Окружностями отмечены поврежденные строки.

Оси PCA и их пределы фиксированы для всех четырех панелей и включают все точки. Поэтому перемещение шумных объектов можно сравнивать непосредственно. Черная окружность означает, что строка была изменена; она не означает, что алгоритм распознал выброс. Все клиенты, включая шумные, получают кластер.

Наиболее удаленные поврежденные точки расширяют облака и увеличивают ошибку относительно центроидов. Основные группы визуально сохраняются, хотя точки около границ могут менять кластер. Выраженного разрушения разбиения при выбранной одно-координатной модели шума и k=4 не наблюдается.

При 10% шума средний силуэт k-Means уменьшается с 0,2893 до 0,2509. Средний ARI неизмененных объектов равен 0,9663. Эти показатели описывают соответственно разделимость шумных данных и сохранение исходного разбиения; они отвечают на разные вопросы.

10 Точечные графики k Medoids при шуме

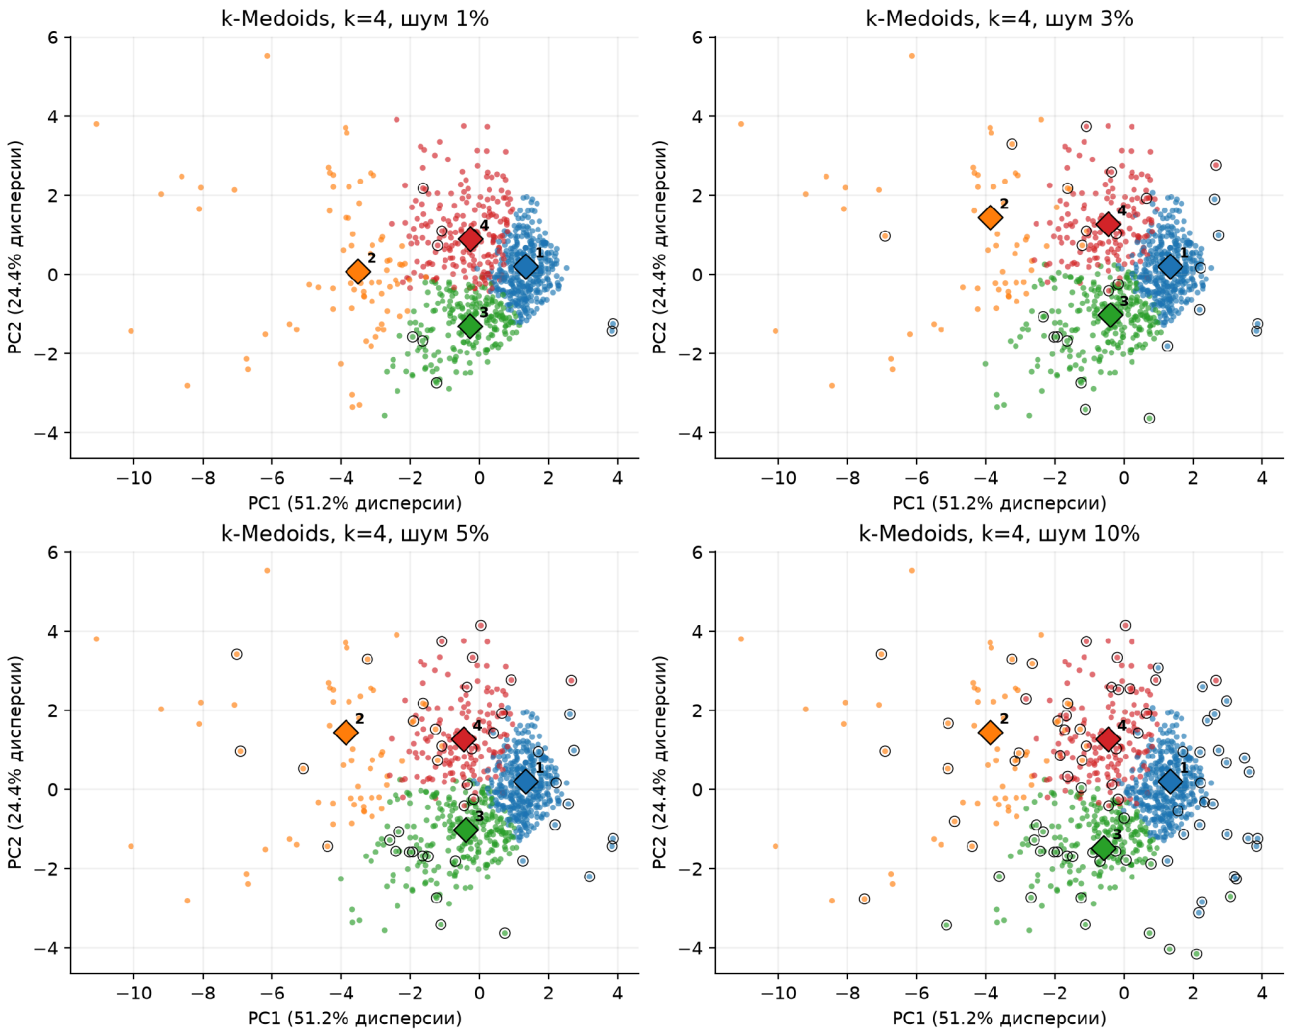


Рисунок 5. k-Medoids с квадратичной целью, k=4, seed=2026. Окружности - поврежденные строки; ромбы - медоиды.

Медоиды остаются строками того набора, который получил алгоритм. Если зашумленная строка выбрана медоидом, используются ее измененные координаты. Ограничение на реальные объекты делает представителей интерпретируемыми, но само по себе не исключает влияние повреждений.

При 10% шума средний силуэт уменьшается с 0,2720 до 0,2387, средний ARI неискаженных строк равен 0,9127. В данной серии квадратичный PAM сохраняет исходное разбиение хуже k-Means по среднему ARI. Ссылка на общую устойчивость медоидов не заменяет проверки конкретной цели и данных.

ARI при 3% шума ниже, чем при 5% и 10% у обоих методов. При расширении множества поврежденных строк оптимизатор может переходить к другому локальному решению; кроме того, сравниваются разные подмножества неискаженных клиентов. Поэтому доля шума не задает монотонную зависимость ARI.

11 Устойчивость и выводы

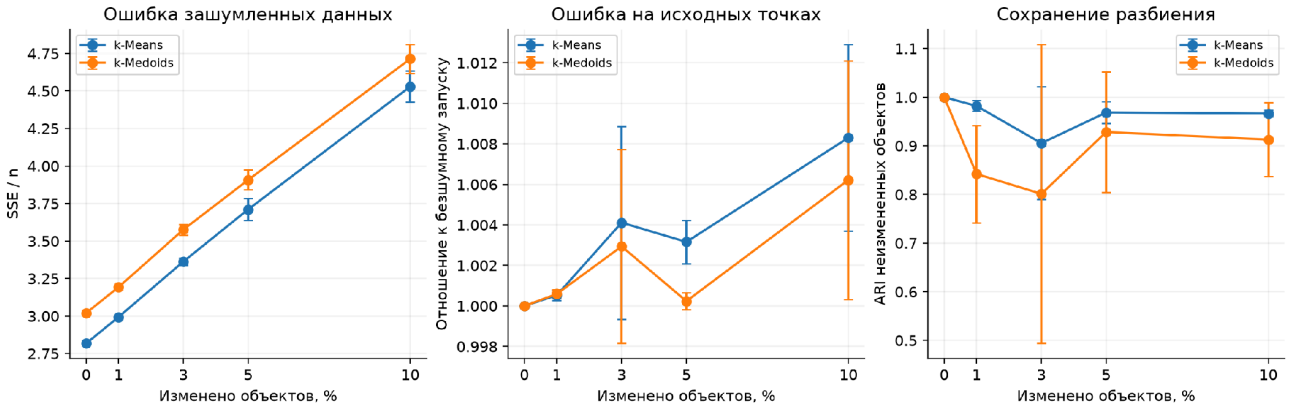


Рисунок 6. k=4. Ошибка шумных данных, ошибка исходных точек относительно шумных представителей и ARI неизмененных строк.

При 10% шума ошибка на исходных координатах всех 850 точек увеличивается только на 0,83% для k-Means и 0,62% для k-Medoids. В отличие от прироста SSE на поврежденных данных, это свидетельствует об умеренном изменении положения представителей. Метрика отражает качество покрытия исходных точек и не заменяет ARI для оценки сохранения членства в группах.

Для выбранных признаков разумным рабочим вариантом является k=4: он дает наибольший средний силуэт у обоих методов и понятные профили групп. Силуэт около 0,27–0,29 показывает частичное перекрытие, поэтому результаты не подтверждают существование четырех строго разделенных естественных классов.

Квадратичный k-Medoids в данном эксперименте не имеет преимущества над k-Means по сохранению разбиения. Вывод ограничен выбором признаков, шкалой, шумом в одной координате величиной 3–6 стандартных отклонений и тремя повторами. В ноутбуке отдельно доступен PAM с обычными расстояниями; его цель следует сравнивать отдельно от SSE.

11 1 Проверка программы

k-Means совпал с независимым sklearn на простом наборе с известными группами. PAM проверен полным перебором медоидов на малом наборе и перебором всех одиночных обменов на случайной матрице. Проверены убывание цели, крайние k=1 и k=n, воспроизводимость и точное число шумных строк. Сумма ошибок экспортированных объектов совпадает с SSE. Все ячейки ноутбука выполнены последовательно; в основном эксперименте сохранены 210 метрик и 178 500 назначений.

11 2 Использованные материалы

1. Цымблер М. Л. Задача кластеризации данных. Лекция от 23.04.2021, «04 Кластеризация», слайды 9–14, 27–30, 64, 67–68.

2. customers.zip: customers.csv и custmers.txt, материалы задания ЮУрГУ.

3. «03 Классификация-2» и «02 Шаблоны»: контекст других задач анализа данных; целевые метки и частые наборы в этой работе не используются.