# Иерархическая кластеризация клиентов банка

*Отчет по практической работе*

Дисциплина «Основы интеллектуального анализа данных»

На данных 850 клиентов исследованы четыре меры связи агломеративной кластеризации и выполнено сравнение с ранее полученными разбиениями k-Means и k-Medoids. Ward формирует более компактные группы, чем остальные иерархические методы, однако по SSE и устойчивости уступает k-Means в проведенных экспериментах. Высокие силуэты Single linkage и Group average сопровождаются сильным дисбалансом размеров кластеров.

## 1 Формулировка задания

Разработать программу иерархической кластеризации, принимающую набор данных и меру схожести кластеров: Single linkage, Complete linkage, Group average или Ward distance. Меру расстояния между объектами допускается фиксировать. Результат необходимо визуализировать в виде дендрограммы.

Провести эксперименты на наборе данных из работы «Разделительная кластеризация», сравнить результаты с предыдущей работой, а также сопоставить четыре меры связи между собой. Подготовить структурированный отчет с формулировкой задания, ссылкой на исходные материалы, рисунками и содержательными пояснениями.

### Материалы работы

Ссылка на каталог репозитория: https://github.com/DexScen/IntDataUNI/tree/main/intdata5

В каталог входят автономный ноутбук Customers_Hierarchical_Clustering_Colab.ipynb, исходные модули src, набор customers.csv с описанием, архив результатов предыдущей работы и результаты текущих экспериментов. Отчет подготовлен в редактируемом формате DOCX.

Для запуска в Google Colab достаточно загрузить IPYNB и выполнить все ячейки. Дополнительная загрузка данных и подключение Google Drive не требуются. Параметры METHOD, K, DATA_PATH и FEATURE_COLUMNS задаются в начале ноутбука.

## 2 Данные и подготовка признаков

Использована точная копия customers.csv из предыдущей практической работы: 850 строк и 10 столбцов. Совпадение исходного файла контролируется SHA-256; порядок строк и параметры подготовки сохранены. Это позволяет сравнивать разбиения одних и тех же объектов без изменения исходных условий.

| Поле | Смысл | Использование |
|---|---|---|
| Row и CustomerId | Порядковый номер и идентификатор | Исключены |
| Age | Возраст в полных годах | Признак |
| YearsEmployed | Трудовой стаж в полных годах | Признак |
| Income | Годовой доход в тысячах долларов | Признак |
| CardDebt | Задолженность по карте | Признак |
| OtherDebt | Прочие задолженности | Признак |
| DebtIncomeRatio | Отношение долга к доходам | Признак |
| Education | Целочисленный код образования | Исключен |
| Defaulted | Признавался банкротом, 0 или 1 | Исключен |

В шести используемых признаках пропусков нет, поэтому сохранены все 850 клиентов. В Defaulted отсутствуют 150 значений. Этот столбец не участвует ни в вычислении расстояний, ни в выборе «правильных» кластеров. Education исключен, поскольку расстояние между кодами категорий не имеет заданного количественного смысла. Идентификаторы не характеризуют свойства клиента.

Каждый числовой признак стандартизован относительно всего исходного набора. Стандартное отклонение вычисляется с ddof=0, как в предыдущей работе.

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}$$

Евклидово расстояние вычисляется по всем шести стандартизованным признакам. Без масштабирования доход и абсолютные долги могли бы определять результат сильнее возраста и стажа только из-за единиц измерения. Стандартизация выравнивает масштабы, но не устраняет корреляцию финансовых признаков.

Для другого CSV программа поддерживает явный список числовых полей, заполнение пропусков медианами и проверку конечности значений. Константным полям назначается масштаб 1. Для customers заполнение пропусков не потребовалось. В дополнительном эксперименте с шумом исходные средние и масштабы фиксированы.

# 3 Алгоритм и меры связи

Реализована агломеративная схема слайда 40 лекции «04 Кластеризация». Первоначально каждый объект образует собственный кластер. На каждом шаге выбирается пара с минимальным межкластерным расстоянием, группы объединяются, после чего обновляются расстояния до нового кластера. Процесс заканчивается после 849 слияний. Ни случайная инициализация, ни заранее заданное k для построения дерева не требуются.

Для кластеров A и B и евклидовой метрики d используются следующие правила (меры Min, Max и Avg приведены на слайдах 45–54 лекции).

$$d_{single}(A,B) = min_{a\in A,\, b\in B}\, d(a,b)$$

$$d_{complete}(A,B) = max_{a\in A,\, b\in B}\, d(a,b)$$

$$d_{average}(A,B) = \frac{1}{|A|\,|B|}\,\Sigma_{a\in A}\,\Sigma_{b\in B}\, d(a,b)$$

Single ориентируется на ближайшую пару и допускает цепочки объектов. Complete учитывает наиболее удаленную пару. Group average усредняет расстояния всех пар объектов из разных кластеров. При слиянии среднее взвешивается размерами исходных групп: это UPGMA, а не полусумма двух расстояний независимо от мощностей кластеров.

Ward выбирает слияние с минимальным увеличением суммы квадратов отклонений объектов от центроидов. Если μ обозначает центроид, то

$$\Delta SSE(A,B) = \frac{|A|\,|B|}{|A|+|B|}\,\|\mu_A - \mu_B\|^2$$

$$h(A,B) = (2\,\Delta SSE(A,B))^{1/2}$$

В дерево записывается высота h, согласованная с определением SciPy, а не сама ΔSSE. Поэтому шкалу Ward нельзя трактовать как обычное расстояние между центроидами или напрямую сравнивать по величине со шкалами других мер.

Матрица дерева содержит номера объединенных узлов, высоту и число исходных объектов. Для k групп выполняются первые n−k слияний. Такой разрез возвращает ровно k непустых групп даже при совпадающих высотах. Основная реализация использует полный поиск минимума матрицы: $O(n^3)$ времени и $O(n^2)$ памяти, что соответствует базовой оценке на слайде 61. Проверки описаны в разделе 10.

# 4 Дендрограммы четырех методов

Для каждой меры построено полное дерево на 850 объектах. Для чтения рисунка показаны последние 30 ветвей; скобки у листьев содержат число объектов свернутой ветви. Укрупнение изображения не меняет дерево и вычисленные метрики. Полные дендрограммы без усечения сохранены в материалах работы.

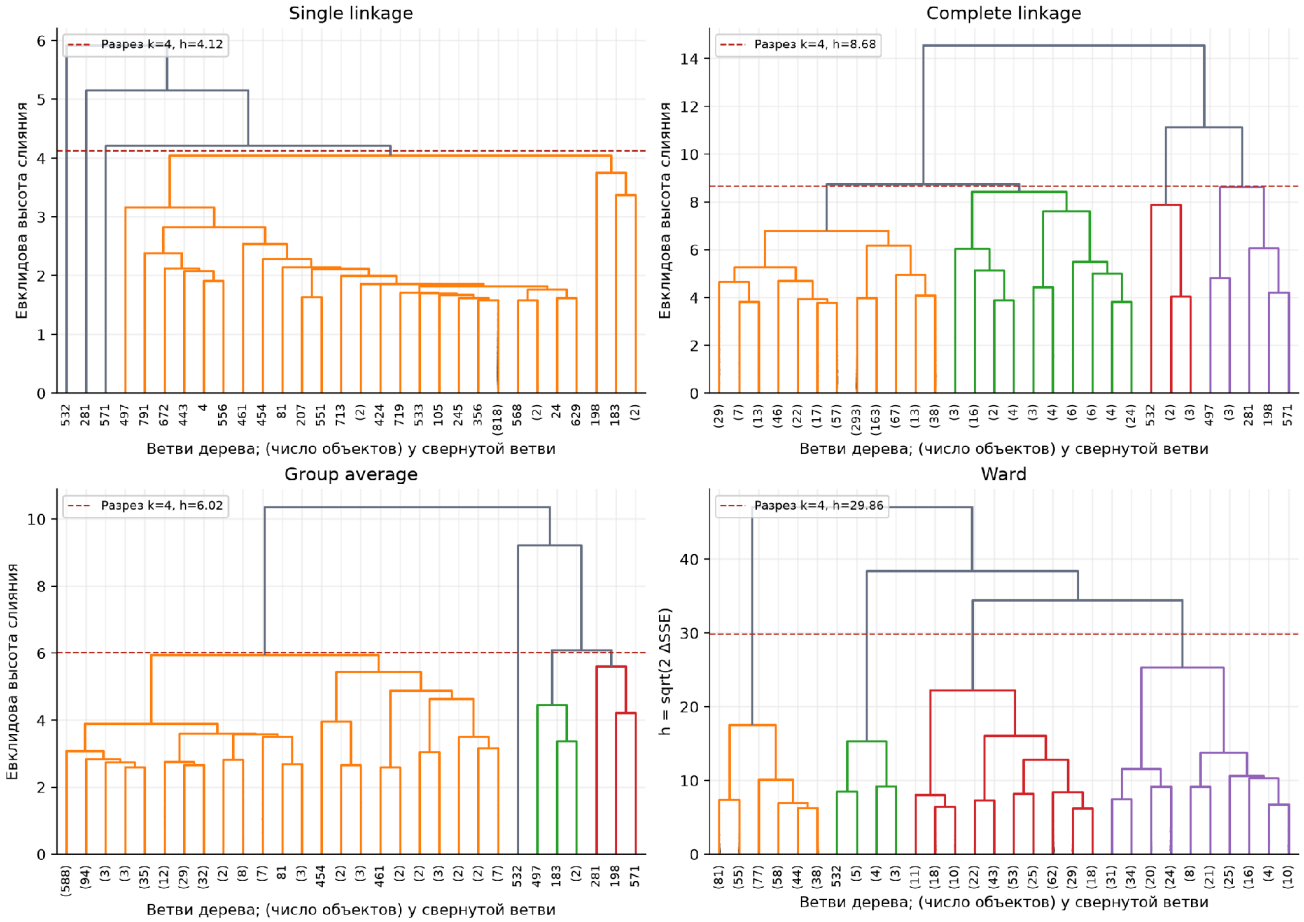



**Рисунок 1 Дендрограммы Single linkage, Complete linkage, Group average и Ward при k=4**

Пунктирная линия показывает разрез, дающий четыре группы. По вертикали отложена высота слияния, а не номер шага. Большой вертикальный промежуток перед объединением ветвей означает, что группы сохранялись раздельно при значительном увеличении межкластерного расстояния. Горизонтальные позиции листьев служат порядком отображения и не являются значениями признаков.

У Single linkage почти все клиенты соединяются через цепочки ближайших соседей до присоединения трех удаленных объектов. Group average также сохраняет несколько малых удаленных ветвей. Complete выделяет более крупные крайние группы. Ward распределяет клиентов между несколькими содержательно различающимися группами, поскольку каждое слияние оценивается через прирост SSE.

# 5 Сопоставление мер и числа кластеров

| Мера связи | SSE к центроидам | Силуэт | Размеры групп при k=4 |
|---|---|---|---|
| Single linkage | 4699,50 | 0,669 | 847 / 1 / 1 / 1 |
| Complete linkage | 3445,36 | 0,412 | 765 / 72 / 7 / 6 |
| Group average | 4304,58 | 0,678 | 842 / 4 / 3 / 1 |
| Ward | 2661,26 | 0,233 | 353 / 291 / 193 / 13 |

Минимальную SSE среди четырех иерархических методов дает Ward. При этом наибольший силуэт у Group average: 0,678 против 0,233 у Ward. Силуэт оценивает геометрическую отделимость, но не требует сбалансированных или практически полезных сегментов. У Group average в одной группе находятся 842 клиента (99,06%), у Single - 847 (99,65%); несколько крайних объектов хорошо отделены от основной массы. Поэтому выбор только по среднему силуэту дал бы сомнительное решение для сегментации клиентов.

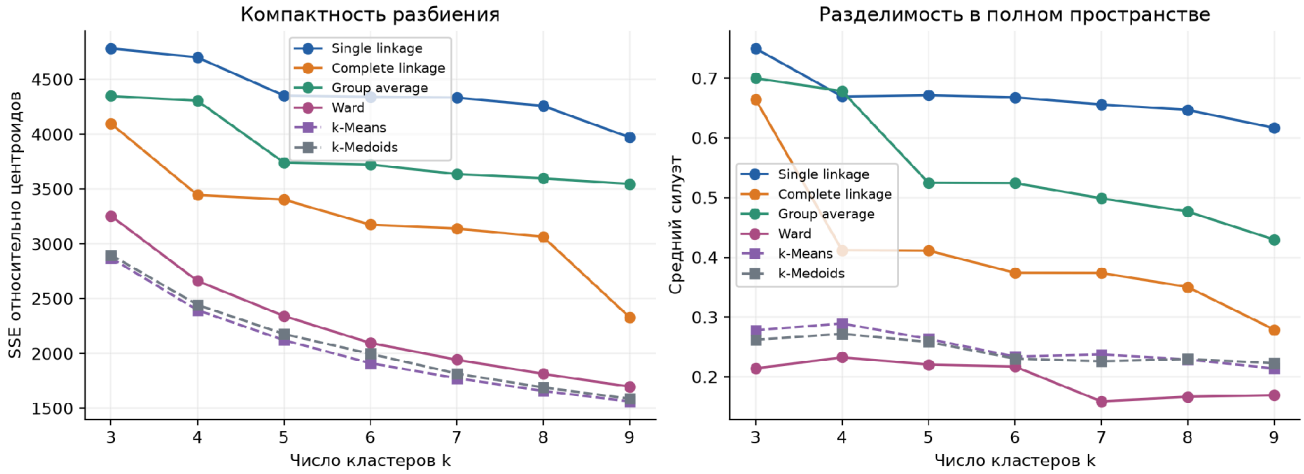



**Рисунок 2 SSE к центроидам и средний силуэт при k от 3 до 9**

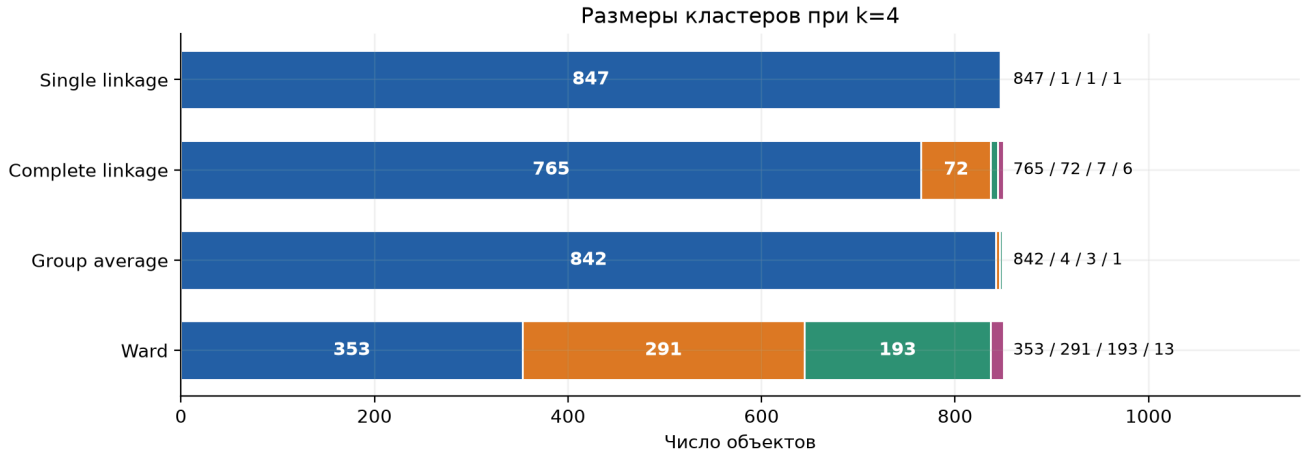



**Рисунок 3 Размеры четырех кластеров в порядке убывания**

Диапазон k=3…9 совпадает с предыдущей работой. Разрез k=4 сохранен для сопоставления, а не объявлен доказанным числом естественных групп. SSE иерархических разрезов убывает при увеличении k вследствие дробления групп, поэтому одного уменьшения SSE недостаточно для выбора k. Высокие силуэты Single и Group average в исследуемом диапазоне следует читать вместе с таблицей размеров, сохраненной для каждого разреза.

# 6 Сравнение с разделительной кластеризацией

Использованы реальные сохраненные результаты предыдущей работы: k-Means (алгоритм Ллойда) и k-Medoids (полный PAM SWAP), по пять стартов для зерен 2026, 2027 и 2028. Основной вариант PAM минимизировал сумму квадратов расстояний до медоидов. Числа ниже усреднены по этим трем запускам; иерархический метод детерминирован и не усредняется по случайным стартам.

| Метод при k=4 | SSE к центроидам | SSE к представителям | Силуэт |
|---|---|---|---|
| k-Means | 2395,03 | 2395,03 | 0,289 |
| k-Medoids | 2443,14 | 2567,11 | 0,272 |
| Ward | 2661,26 | Не применяется | 0,233 |

Общий критерий сравнения - SSE относительно центроидов уже полученных кластеров. Для k-Medoids он пересчитан заново: 2443,14, тогда как прежняя целевая функция до медоидов равна 2567,11. Это разные величины. SSE Ward 2661,26 выше SSE k-Means на 11,12% и SSE разбиения k-Medoids на 8,93%. Жадные слияния Ward необратимы и не выполняют последующее перераспределение объектов, поэтому сходство критерия не гарантирует совпадения с k-Means.

| Иерархический метод | ARI с k-Means | ARI с k-Medoids |
|---|---|---|
| Single linkage | 0,006 ± 0,000 | 0,006 ± 0,000 |
| Complete linkage | 0,141 ± 0,000 | 0,116 ± 0,000 |
| Group average | 0,017 ± 0,000 | 0,015 ± 0,000 |
| Ward | 0,450 ± 0,002 | 0,539 ± 0,000 |

ARI сравнивает состав групп независимо от номеров кластеров и корректирует случайные совпадения. Значение 1 означает одинаковое разбиение, около 0 - согласованность на уровне случайного сопоставления; возможны отрицательные значения. Это мера сходства двух разбиений, а не точность по известным классам.

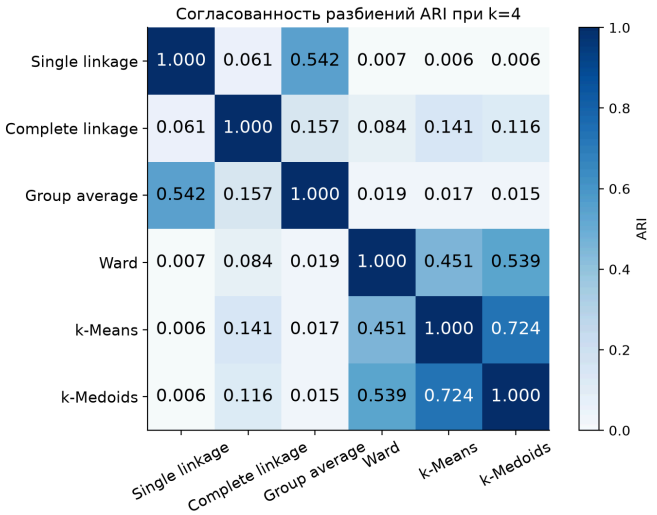



**Рисунок 4 Попарный ARI при k=4 для прежних запусков с seed=2026**

Ward наиболее близок к обоим разделительным методам. Между Single linkage и Group average ARI равен 0,542, что отражает сходство их крупных основных групп. Совпадение групп не свидетельствует само по себе об их полезности.

# 7 Визуализация разбиений в проекции PCA

Для всех рисунков применена одна PCA, обученная на чистой стандартизованной матрице. Первая компонента объясняет 51,21%, вторая - 24,36%, вместе - 75,56% дисперсии. Алгоритмы обучались и оценивались в шести измерениях. PCA служит способом показать структуру на плоскости и теряет 24,44% дисперсии.

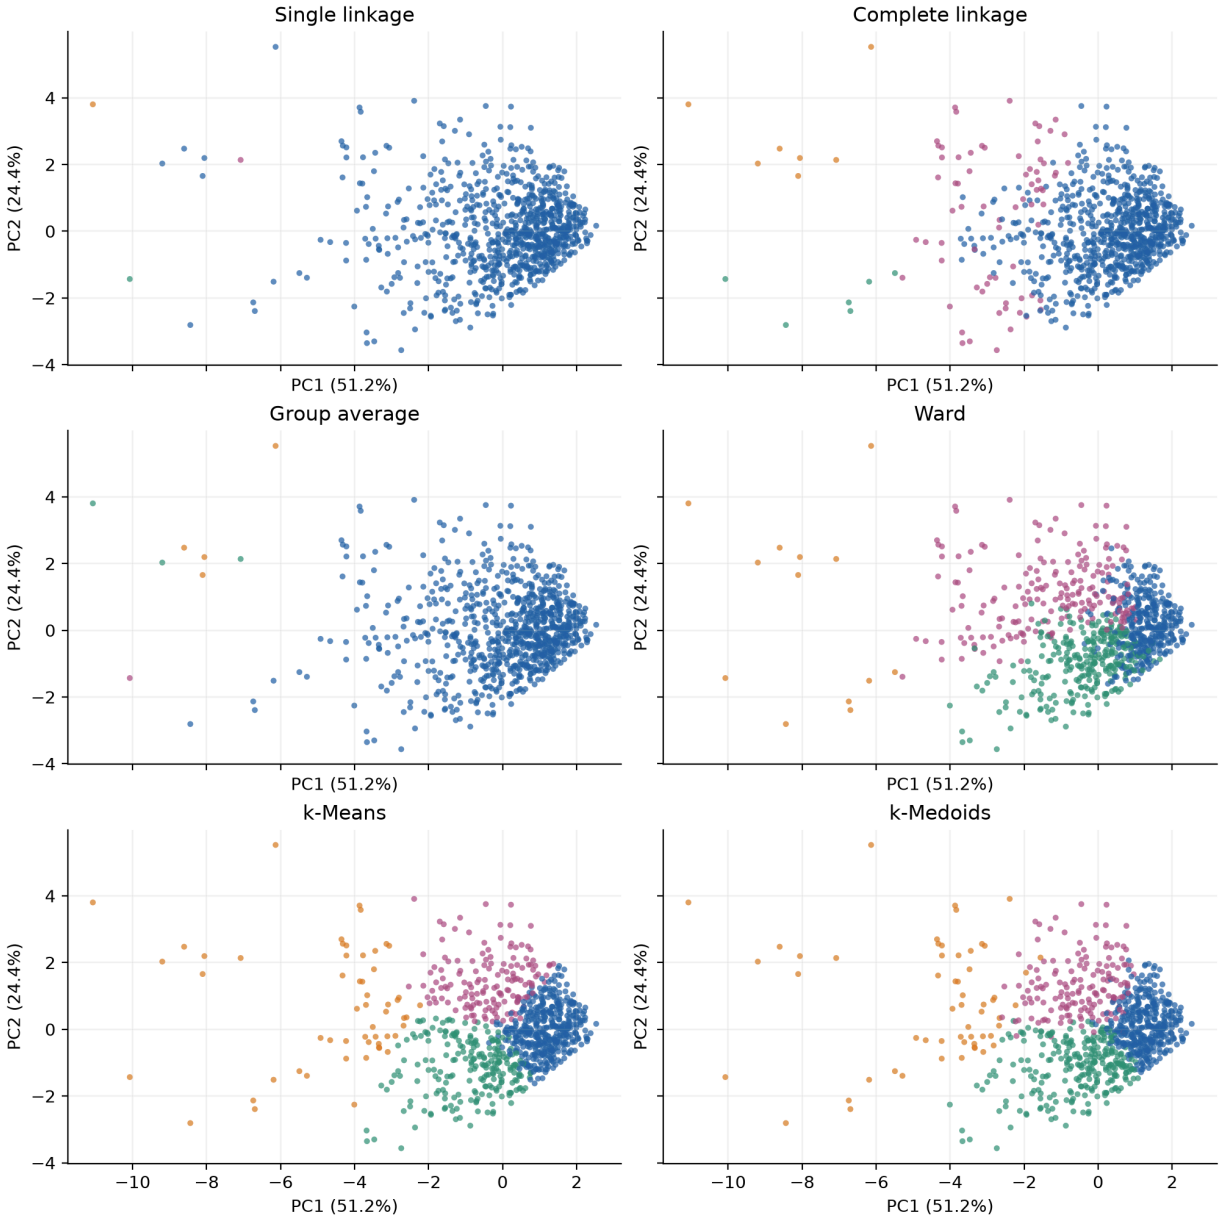



**Рисунок 5 Четыре иерархических метода и прежние разделительные разбиения при k=4**

Цвета сопоставлены с исходным k-Means по максимальному пересечению кластеров. На рисунке видно доминирование одной группы у Single и Group average. Ward, k-Means и k-Medoids разделяют основную массу клиентов на несколько сегментов, но границы различаются, что согласуется с ARI. Перекрытие точек в проекции нельзя интерпретировать как полное совпадение исходных признаков.

# 8 Содержательный смысл кластеров Ward

Для интерпретации выбран разрез Ward на четыре кластера. Номера групп соответствуют CSV результатов и назначены по порядку первого входящего в группу объекта. Приведены средние исходных признаков, а не координаты PCA.

| Кластер | n | Возраст | Стаж | Доход | Долг по карте | Прочие долги | Долг к доходу |
|---|---|---|---|---|---|---|---|
| 1 | 291 | 41,0 | 12,3 | 57,7 | 1,28 | 2,42 | 7,17 |
| 2 | 193 | 37,4 | 9,3 | 53,4 | 3,08 | 6,12 | 18,42 |
| 3 | 353 | 28,4 | 4,5 | 27,7 | 0,62 | 1,44 | 7,87 |
| 4 | 13 | 46,7 | 23,1 | 216,0 | 11,77 | 17,10 | 17,40 |

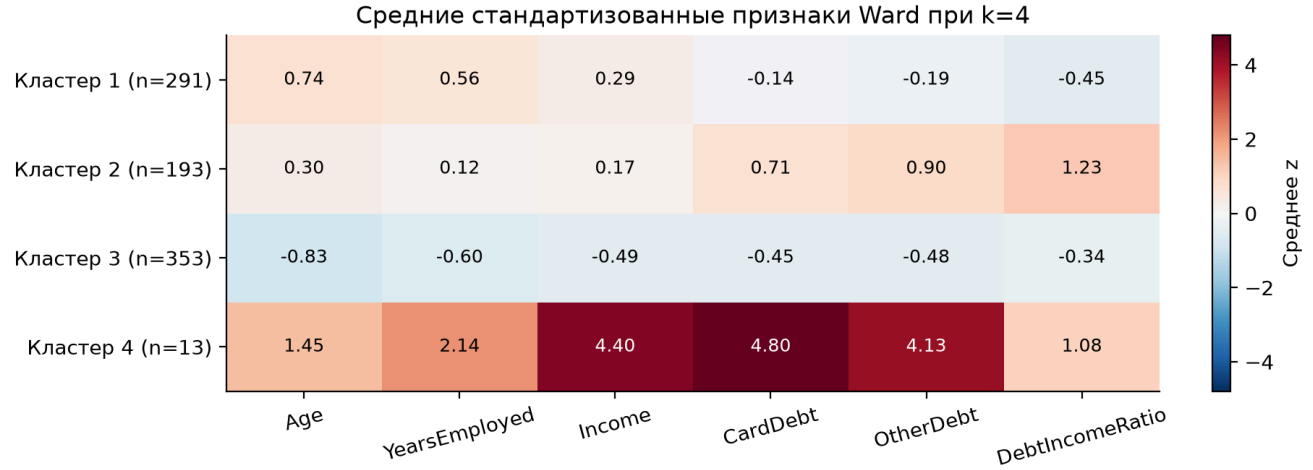



**Рисунок 6 Средние стандартизованные профили кластеров Ward**

Кластер 1 включает 291 клиента. Средний возраст - 41,0 года, стаж - 12,3 года, доход - 57,7 тыс. долларов в год. Отношение долга к доходу 7,17 ниже среднего по набору 10,17. Это более опытные клиенты с умеренной долговой нагрузкой относительно дохода.

Кластер 2 содержит 193 клиента. При доходе 53,4 тыс. долларов отношение долга к доходу достигает 18,42; абсолютные долги также выше среднего. От первого кластера эта группа отличается прежде всего долговой нагрузкой.

Кластер 3 объединяет 353 клиента со средним возрастом 28,4 года, стажем 4,5 года и доходом 27,7 тыс. долларов. Долги в абсолютных величинах ниже, а отношение долга к доходу равно 7,87. Это самая многочисленная группа.

Кластер 4 включает 13 клиентов с очень высоким доходом: в среднем 216,0 тыс. долларов. Средний возраст - 46,7 года, стаж - 23,1 года; долги по карте и прочие долги составляют 11,77 и 17,10 в единицах исходного набора. Группа описывает крайние значения финансовых признаков и требует осторожной интерпретации из-за небольшой численности.

Это описательные профили полученных кластеров. Они не являются оценкой вероятности банкротства или подтвержденными банковскими категориями: Defaulted не использовался, внешние метки сегментов отсутствуют.

# 9 Дополнительный эксперимент с шумом

Для сопоставления с предыдущей работой дополнительно проверена устойчивость при k=4. Для каждого из трех зерен ровно 85 различных строк (10% набора) получают сдвиг одной случайной координаты на ±U(3,6) исходных стандартных отклонений. Это модель ошибок измерения, поэтому измененные значения не обрезаются до банковских диапазонов. Все методы получают одинаковые искажения при одном зерне. Средние и масштабы не переобучаются.

ARI вычисляется на 765 неизмененных клиентах между чистым и зашумленным разбиением того же алгоритма. Для k-Means и k-Medoids взяты прежние запуски с теми же зернами. По трем значениям считаются среднее и выборочное стандартное отклонение; интервал на графике не является доверительным.

| Метод | Средний ARI | Стандартное отклонение |
|---|---|---|
| Single linkage | 0,710 | 0,077 |
| Complete linkage | 0,247 | 0,069 |
| Group average | 0,910 | 0,155 |
| Ward | 0,502 | 0,110 |
| k-Means | 0,966 | 0,007 |
| k-Medoids | 0,913 | 0,076 |

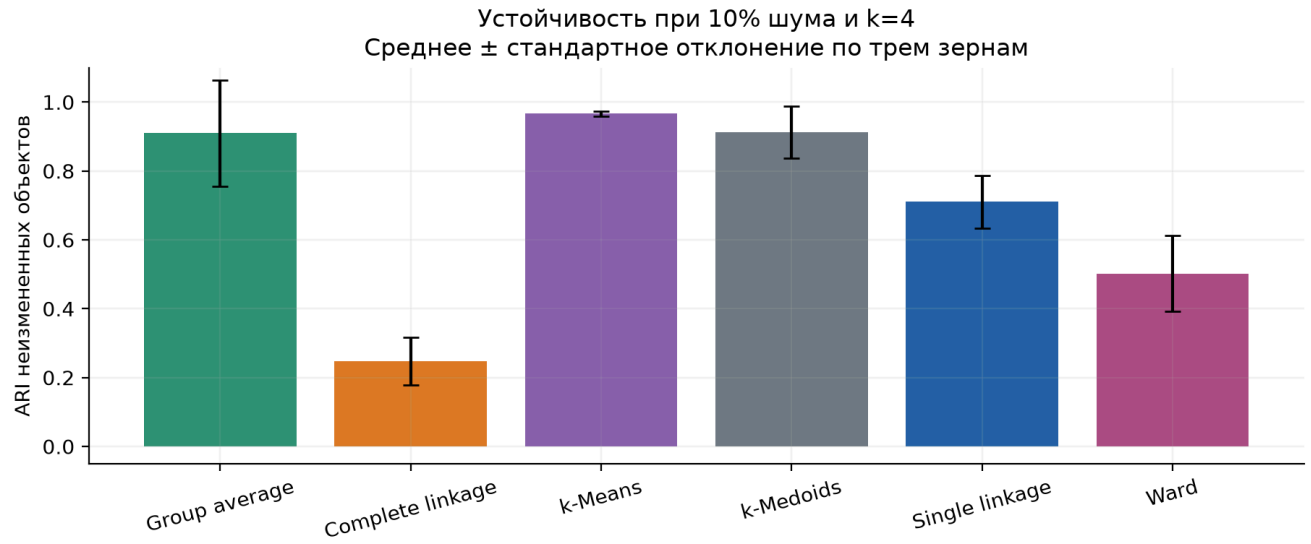



**Рисунок 7 Сохранение разбиения неизмененных объектов при 10% шума**

Наиболее устойчив k-Means: ARI 0,966 ± 0,007. У k-Medoids он равен 0,913 ± 0,076, у Ward - 0,502 ± 0,110. Даже искажение части строк может изменить ранние слияния Ward и последующую структуру дерева, поэтому неизмененные клиенты получают другое разбиение.

Высокая устойчивость Group average (0,910 ± 0,155) сопровождается сохранением большой основной группы: в зашумленных запусках ее средний размер - 839 клиентов. Такой результат нельзя трактовать как превосходство в сегментации. Выводы относятся к выбранному набору, схеме искажения и трем зернам; они не устанавливают общего рейтинга алгоритмов.

# 10 Проверка программы и выводы

Основное построение деревьев и разрезы реализованы в src/hierarchy.py. SciPy применяется для попарных расстояний, отрисовки и независимой проверки; основная агломерация не вызывает scipy.cluster.hierarchy.linkage. Проверяющий скрипт сопоставляет рекуррентную реализацию с прямыми определениями четырех мер на трех малых случайных наборах. Дополнительно проверяются все k, дубликаты, неверные параметры и заполнение пропусков.

На customers максимальное расхождение высот с независимой реализацией SciPy составило 1.42e-14. Для всех 28 сравниваемых разрезов ARI равен 1. Для Ward проверено тождество: сумма $h^2/2$ по выполненным слияниям равна SSE разреза. При равных расстояниях возможны разные допустимые порядки слияний; собственная программа использует фиксированный порядок слотов.

Все ячейки передаваемого ноутбука выполнены последовательно с сохранением реальных таблиц и изображений. Расчет включает четыре исходных дерева, 28 разрезов и 12 дополнительных зашумленных деревьев. Сохранены параметры подготовки, метки, linkage-матрицы, версии библиотек и данные для сравнения. Встроенный архив прежней работы можно проверить повторным запуском прежних реализаций через параметр RECOMPUTE_PARTITION_BASELINES.

### Выводы

Разработанная программа поддерживает все четыре требуемые меры связи и визуализирует полученную иерархию. Для customers Ward дает наименьшую SSE среди исследованных иерархических методов и наиболее близок к прежним разбиениям. Однако при k=4 k-Means дает более компактные группы и лучше сохраняет разбиение в проведенном эксперименте с шумом.

Single linkage и Group average преимущественно отделяют крайние наблюдения от почти единой основной группы. Их высокий силуэт показывает разделимость таких крайних ветвей, но не подтверждает содержательную сегментацию большинства клиентов. Выбор меры связи требует совместного анализа дендрограммы, размеров групп, SSE, силуэта, устойчивости и профилей признаков.

### Источники и воспроизведение

1. М.Л. Цымблер. «04 Кластеризация». 23.04.2021. Слайды 33–40, 45–54, 61, 64, 67. Материалы дисциплины ЮУрГУ.

2. customers.csv и custmers.txt из задания «Разделительная кластеризация». Архив результатов предыдущей работы сохранен вместе с текущими исходниками.

3. Документация SciPy по linkage и соглашению о высоте Ward

4. Документация scikit-learn по силуэту и ARI

Локальный запуск из каталога проекта: python src/experiments.py. Проверки: python src/check_algorithms.py. Один запуск: python src/hierarchy.py data/customers.csv --method ward --k 4. Полные команды и состав выходных файлов приведены в README.md.