Поиск частых наборов товаров алгоритмом Apriori

Основы интеллектуального анализа данных

Формулировка задания

Разработать программу поиска частых наборов объектов алгоритмом Apriori. Программа принимает набор транзакций, порог поддержки и способ сортировки результата: по убыванию поддержки либо лексикографически. Для каждого найденного набора требуется вывести его состав и поддержку.

На данных baskets.csv провести эксперименты при порогах 1%, 3%, 5%, 10% и 15%. Построить диаграммы времени выполнения и количества частых наборов различной длины в зависимости от порога. Объяснить полученные результаты.

Репозиторий

Ссылка на каталог репозитория: https://github.com/DexScen/IntDataUNI

Данные и реализация алгоритма

Файл baskets.csv содержит 7 501 корзину и 115 различных товаров. Каждая строка соответствует отдельной покупке, названия товаров разделены запятыми. Заголовок отсутствует, кодировка файла - Windows-1251. Средняя длина корзины равна 3,91 товара, максимальная - 20 товаров.

При чтении удаляются пустые поля и пробелы по краям названий. Корзины преобразуются в множества: повтор одного товара внутри корзины не увеличивает поддержку. Всего исключено 39 повторных вхождений товаров. Одинаковые корзины из разных строк сохраняются как отдельные покупки.

Поддержка набора - отношение числа корзин, содержащих все товары этого набора, к общему числу корзин. Набор считается частым, если его поддержка не меньше заданного порога. Например, порог 1% для данной базы требует присутствия набора не менее чем в 76 корзинах.

Алгоритм Apriori реализован на Python. Сначала находятся частые одиночные товары. Затем частые наборы предыдущего уровня соединяются по общему префиксу. Кандидаты с редкими подмножествами предыдущей длины отбрасываются. Для остальных поддержка подсчитывается проходом по транзакциям. Алгоритм завершается, когда новых частых наборов не остаётся.

Функция apriori(transactions, min_support, order) возвращает пары «набор, поддержка». Режим support задаёт сортировку по убыванию поддержки, lexicographic - лексикографическую сортировку. При равной поддержке используется лексикографический порядок.

Эксперименты и быстродействие

Все эксперименты выполнены на одной базе из 7 501 транзакции. Для каждого порога сделан один замер полного вызова apriori с сортировкой support через perf_counter(). Чтение CSV, вывод таблиц и построение графиков в замер не входят.

Измерения выполнены 14.09.2026 в локальном Jupyter: Python 3.12.14, macOS 15.7.4, архитектура arm64. Результаты сохранены в ноутбуке.

Таблица 1. Результаты экспериментов

Порог, %	1 товар	2 товара	3 товара	Всего наборов	Время, с
1	74	170	17	261	0,444495
3	36	19	0	55	0,098061
5	25	3	0	28	0,046367
10	7	0	0	7	0,006638
15	5	0	0	5	0,004991

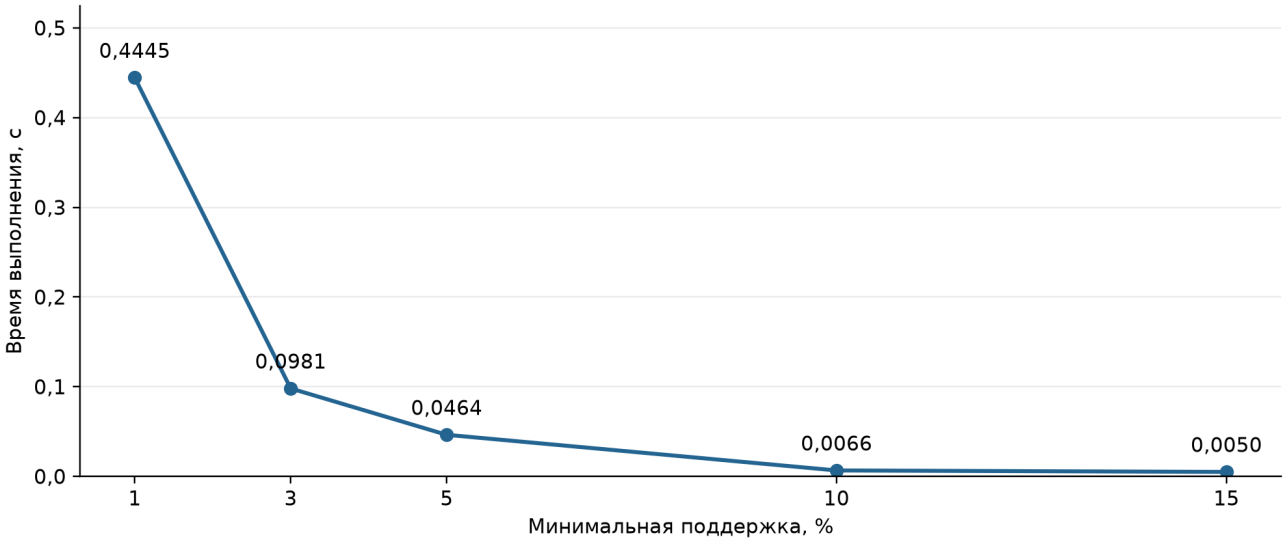


Рисунок 1. Время выполнения Apriori при изменении порога поддержки

При повышении порога время выполнения уменьшилось с 0,444495 с до 0,004991 с. Более строгий порог сокращает число частых наборов, из которых формируется следующий уровень. При 1% из 74 одиночных товаров получается 2 701 кандидат в пары, а при 15% из 5 товаров - только 10 кандидатов. Поэтому требуется меньше проверок вхождения наборов в корзины.

Каждый порог измерялся один раз. Значения характеризуют данный запуск; при повторном выполнении время может отличаться из-за нагрузки среды.

Количество частых наборов различной длины

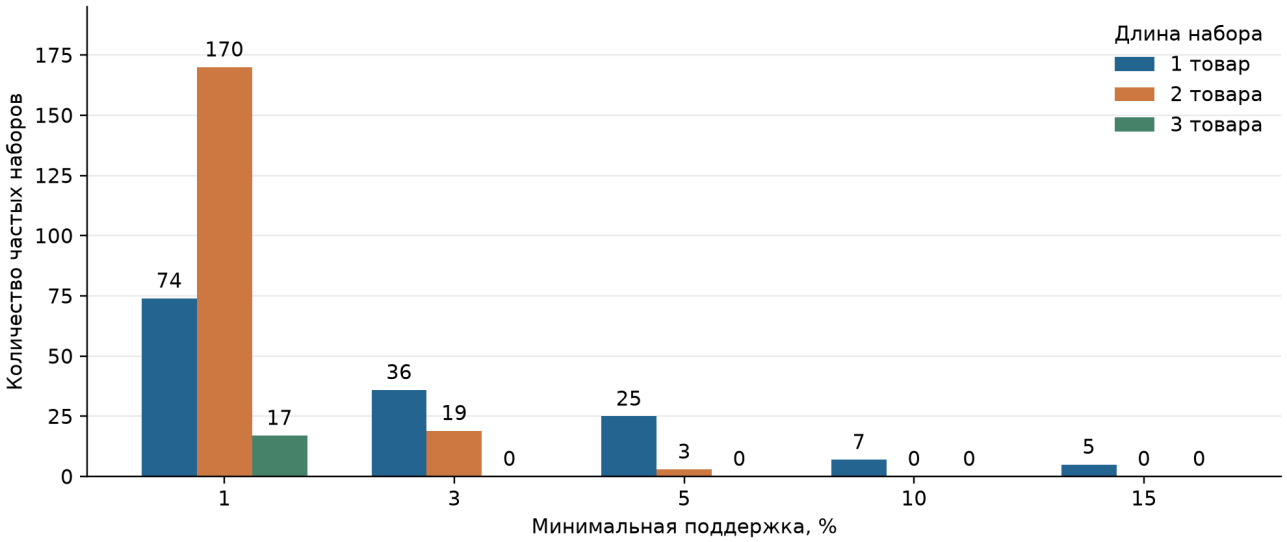


Рисунок 2. Количество частых наборов разной длины при изменении порога

При пороге 1% найден 261 частый набор: 74 одиночных товара, 170 пар и 17 троек. При 3% остаются 36 одиночных товаров и 19 пар, при 5% - 25 одиночных товаров и 3 пары. Пороги 10% и 15% оставляют соответственно 7 и 5 одиночных товаров. Наборы длины четыре и более не найдены даже при минимальном исследованном пороге 1%.

Пояснения и выводы

Результат объясняется антимонотонностью поддержки: поддержка набора не может превышать поддержку любого его поднабора. Совместное появление нескольких товаров не может встречаться чаще, чем появление каждого из них. Поэтому при повышении порога множество частых наборов может только сокращаться, а длинные сочетания в данной базе исчезают раньше одиночных товаров.

Самый частый набор - {минеральная вода}: 1 788 корзин, или 23,84%. Самая частая пара - {макароны, минеральная вода}: 459 корзин, или 6,12%. Её поддержка ниже 10%, что объясняет отсутствие любых частых пар при порогах 10% и 15%. Наиболее частая тройка {говяжий фарш, макароны, минеральная вода} встречается в 129 корзинах (1,72%) и перестаёт быть частой при пороге 3%.

Снижение порога позволяет обнаружить больше сочетаний товаров, но увеличивает вычислительные затраты. Повышение порога ускоряет поиск и оставляет наиболее распространённые покупки. Для поиска совместных покупок на этой базе пороги 10-15% слишком высоки: при них нет наборов из нескольких товаров. Высокая поддержка показывает частоту появления набора, но сама по себе не доказывает причинную связь между товарами.